



江西财经大学  
JIANGXI UNIVERSITY OF FINANCE AND ECONOMICS

学校代码 \_\_\_\_\_

密 级 \_\_\_\_\_

中图分类号 \_\_\_\_\_

UDC \_\_\_\_\_

# 硕士学位论文

## MASTER DISSERTATION

论文题目 基于经验似然的 ARX 模型

(中文) 序列相关检验

论文题目 An Empirical Likelihood-based Serial

(英文) Correlation Test in ARX Models

作 者 李汉青 导 师 刘小惠

申请学位 硕 士 学院名称 统计学院

学科专业 统计学 研究方向 时间序列

二〇二三年六月

## 摘要

ARX 模型是时间序列分析中的常用模型，其结合自回归项与外生变量的结构使得它拥有了远超自回归模型或简单线性回归的应用场景，相关的学科方向包括但不仅限于金融统计建模、环境监测、机械工程等。

在回归分析，特别是时间序列相关的模型拟合中，序列相关检验是一个非常重要的步骤。表现出序列相关性的误差项往往意味着模型存在拟合结果不佳、模型误设等严重问题。虽然目前已有不少文献针对该问题做出了杰出的工作，但是近年来，实证经济学家发现在实际金融数据中广泛存在着波动聚集、异方差、重尾，以及误差项序列之间强相关等问题，而这些现象对于现存的序列相关检验方法的稳健性造成了极大的破坏。面对这些新的挑战，学界与业界都迫切需要一个在上述特殊条件下都适用的检验方法。

有鉴于此，本文基于剖面优化经验似然 (Profile Empirical Likelihood, PEL) 为 ARX 模型提出了一个新的序列相关检验方法，并将其数值模拟的结果与现存的 PI(Plug-In) 经验似然检验和 BG(Breusch-Godfrey) 检验进行了对比。数值模拟结果表明，相较 PI 方法在误差项序列之间强相关的情况下严重 Undersized，以及 BG 方法在条件异方差的情况下严重 Oversized 的表现，本文所提的 PEL 方法在上述所有考虑到的情况下都保持了准确的 Size，故而拥有最佳的稳健性质。PEL 序列相关检验方法的提出扩展了现有检验方法的应用所受到的局限，因而具有较大的实际意义。

除此之外，本文还将 PEL 序列相关检验应用于实证研究中。我们分别对一组包含美国股市股票收益率、市盈率、股息率等金融变量的数据集与一组包含臭氧浓度、风速、湿度等环境变量的数据集进行了 ARX 模型拟合与序列相关检验。第一个例子表明，相比传统的预测回归模型，带有自回归项的 ARX 模型在拟合股票收益等金融变量时更为适用且恰当。第二个例子表明，本文中用四组外生气象变量对臭氧浓度这一指标进行拟合的结果并不充分，污染评估所涉及到的变量可能更多，或者存在模型选择方面的问题，实证研究者需要考虑更加复杂的模型。

**关键词：**ARX 模型；序列相关检验；模型检查；经验似然；非参数统计

## Abstract

The ARX model is widely adopted in time series analysis, its structure of combining autoregressive items and exogenous variables brings it much more application scenarios than autoregressive models or simple linear regressions, relevant disciplines include but not limited to financial statistical modeling, environmental monitoring, mechanical engineering, etc.

In regression analysis, specially in model fitting with respect to time series, testing for serial correlation is an important procedure. The error terms which exhibit serial correlations often imply the existence of model inadequacy or model misspecification. Although there have been much outstanding work on this issue, but in recent years, empirical economists have found that in real financial data, there are widespread problems such as volatility clustering, heteroskedasticity, heavy tails, and strong correlations between different error sequences. These phenomena are extremely destructive for the robustness of existing serial correlation test methods. Facing these new challenges, both the academia and the industry urgently need a test method that is applicable under all the above special conditions.

In view of this, this paper proposes a new serial correlation test for ARX models based on Profile Empirical Likelihood (PEL), and compares its numerical simulation results with existing Plug-In (PI) test and Breusch-Godfrey (BG) test. The results show that, in comparison with the serious undersized performance of the PI method in the case of strong correlation between the error sequences, and the severe oversized performance of the BG method in the case of conditional heteroscedasticity, the PEL method proposed in this paper has the best robustness due to its excellent performance of maintaining exact size under all the above considerations. The introduction of the PEL serial correlation test method expands the limitation of the existing test methods, which brings it great practical significance.

In addition, we also applied the PEL serial correlation test to the empirical research. We respectively conducted ARX model fitting and serial correlation tests on a set of financial data including stock returns, price-earning ratios, dividend-yield

ratios and a set of environmental data including ozone concentrations, wind speeds, humidities. The first example shows that, compared with the traditional predictive regression model, the ARX model with autoregressive items is more applicable and appropriate in fitting financial variables such as stock returns. The second example shows that the four sets of exogenous meteorological variable data used in this paper are insufficient to fit the indicator of ozone concentration, and there may be more variables involved in pollution assessment, or there exist problems in model selection, empirical researchers need to consider more complex models.

**Keywords:** ARX models; Serial correlation tests; Diagnostic checking; Empirical likelihood; Nonparametric statistics

## 目 录

|                        |    |
|------------------------|----|
| 1 绪论.....              | 1  |
| 1.1 研究背景与意义.....       | 1  |
| 1.2 文献综述.....          | 4  |
| 1.2.1 ARX 模型文献综述 ..... | 4  |
| 1.2.2 序列相关检验文献综述.....  | 5  |
| 1.2.3 经验似然文献综述.....    | 7  |
| 1.3 待解决的问题与本人工作 .....  | 8  |
| 2 预备知识.....            | 10 |
| 2.1 渐近符号及定义.....       | 10 |
| 2.2 有关引理.....          | 11 |
| 2.3 经验似然方法概述.....      | 13 |
| 2.4 剖面优化经验似然方法.....    | 14 |
| 3 ARX 模型的序列相关检验 .....  | 16 |
| 3.1 检验方法及相关渐近性质 .....  | 16 |
| 3.2 数值模拟.....          | 18 |
| 3.3 理论证明.....          | 30 |
| 3.4 实证研究.....          | 36 |
| 3.4.1 股票收益数据分析.....    | 36 |
| 3.4.2 臭氧浓度数据分析.....    | 42 |
| 4 总结与展望.....           | 45 |
| 4.1 总结.....            | 45 |
| 4.2 展望.....            | 46 |
| 参考文献.....              | 47 |

# 1 绪论

## 1.1 研究背景与意义

时间序列分析是统计学的重要研究方向,其在诸如经济、金融、气候、能源等众多领域有着广泛的应用。与经典的独立同分布 (i.i.d.) 假设不同,时间序列数据通常表现出对于时间、时序相依的特点。基于这一特性,Yule(1927)<sup>[58]</sup> 开创性地提出了自回归 (AR) 模型,该模型构造了一种序列间的线性依赖关系。时至今日,AR 模型已经成为了时间序列分析中最基础,同时也是最常用的模型之一。与之同时发展的还有移动平均 (MA) 模型,以及这两者的混合——自回归移动平均 (ARMA) 模型。以 ARMA 为基础模型族现在已经十分庞大且成熟,例如针对非平稳数据的差分整合移动平均自回归 (ARIMA) 模型,以及针对面板数据的向量自回归移动平均 (VARMA) 模型。更多例子与细节可参见专著 Van der Vaart(2010)<sup>[54]</sup>, Box 等 (2015)<sup>[5]</sup>, Hamilton(2020)<sup>[30]</sup>。

在金融时间序列领域,有一类基于 AR 模型构建,被称为预测回归模型的模型族。该类模型因适合运用在如资产价格可预测性检验与推断等重要问题上而受到广泛关注,其构造为带有滞后的线性回归与自回归的组合,它的一个经典多元形式如下式(1.1)所示:

$$Y_t = \alpha + \beta^\top \mathbf{X}_{t-1} + U_t, \quad \mathbf{X}_t = \boldsymbol{\mu} + \mathbf{A}\mathbf{X}_{t-1} + \mathbf{V}_t, \quad (1.1)$$

其中  $Y_t$  与  $\mathbf{X}_t \in \mathbb{R}^d$  通常代表如资产价格或股票指数等的金融变量,  $U_t$  和  $\mathbf{V}_t \in \mathbb{R}^d$  为  $Y_t$  与  $\mathbf{X}_t$  各自的随机扰动项。在该预测回归模型的左式中,  $\mathbf{X}_{t-1}$  为相较  $Y_t$  带有一阶滞后的预测变量,  $\beta$  为其斜率系数,  $\alpha$  为被预测变量  $Y_t$  的截距项。在右式中,  $\mathbf{X}_t$  自身的变化由向量自回归 (VAR) 模型来刻画,  $\mathbf{A} \in \mathbb{R}^{d \times d}$  为其自回归系数,  $\boldsymbol{\mu} \in \mathbb{R}^d$  为其截距项。

值得注意的是,上面所提到的可预测性检验,即响应变量  $Y_t$  能否由解释变量  $\mathbf{X}_t$  预测的问题,在预测回归模型这一框架下,可以被归结为关于回归系数  $\beta$  的统计推断,即回归系数的显著性检验问题。此问题在金融领域有重大实际意义,因而成为一研究热点,文献众多,且受到学界与业界的持续关注。较早的经典文献有 Fama 和 Schwert(1977)<sup>[24]</sup>, Keim 和 Stambaugh(1986)<sup>[34]</sup>, Fama 和 French(1988)<sup>[23]</sup> 等,



这些文献中的  $Y_t$  代表某个由不同股票组成的投资组合的收益率，而  $\mathbf{X}_{t-1}$  则设置为股息率、当期利率、带有延迟的利率，或者它们的一个函数组合的形式。可预测性问题近年的理论发展有 Zhu 等 (2014)<sup>[59]</sup>，Liu 等 (2019)<sup>[39]</sup>，Cai 等 (2022)<sup>[9]</sup> 等。其中，Zhu 等 (2014)<sup>[59]</sup> 针对实际数据经常表现出非平稳与重尾等性质所带来的挑战，基于经验似然提出了预测回归模型的加权可预测性检验，并使用月度 CRSP 指数对股息率、市盈率等金融变量进行了实证研究。Liu 等 (2019)<sup>[39]</sup> 则为如何在平稳的被预测变量与非平稳的预测变量之间进行可预测性检验提供了另一条思路，其在回归方程中导入预测变量的差分项，从而引入了一种“平衡”结构，解决了既有方法在此种情况下回归系数皆无法显著的问题。

除了用于可预测性的研究之外，预测回归模型的构造还有另一重要意义。早在上世纪末，众多金融实证研究就已广泛提及，在不同的金融变量之间可能大量存在新息 (Innovation) 相关的现象。反应在本文的模型中，即对于(1.1)中  $Y_t$  和  $\mathbf{X}_t$  各自的随机扰动项  $U_t$  和  $\mathbf{V}_t$ ，可能有  $\text{Cov}(U_t, \mathbf{V}_t) \neq 0$  成立。这个现象的直接结果就是回归参数的最小二乘 (OLS) 估计是有偏的，进而破坏基于 OLS 估计的统计推断的有效性。关于这一问题的讨论可参见 Stambaugh(1999)<sup>[50]</sup>，Amihud 和 Hurvich(2004)<sup>[1]</sup>，Chen 和 Deo(2009)<sup>[16]</sup>。

虽然形如(1.1)的预测回归模型在金融时间序列中，特别是金融变量的可预测性统计推断方面有着重要地位，但是其在拟合或预测实际数据的方面仍有较明显的不足。其中一个很明显的不足是，虽然  $Y_t$  关于时序的相依性可以由  $\mathbf{X}_t$  的自相关性解释，但是  $Y_t$  并不能保证自身的自相关性一定是外生的。换言之，如果  $Y_t$  中存在着不可忽略的，与  $\mathbf{X}_t$  不相关的序列相依性，那么使用模型(1.1)进行拟合或预测可能会出现较大的偏误。以下用一个简单的例子说明这个问题。

我们假设真实生成数据的模型为以下过程：

$$Y_t = \tilde{\alpha} + \phi Y_{t-1} + \tilde{\beta}^\top \mathbf{X}_{t-1} + U_t, \quad \mathbf{X}_t = \boldsymbol{\mu} + \mathbf{A} \mathbf{X}_{t-1} + \mathbf{V}_t, \quad (1.2)$$

然而进行模型拟合的却是预测回归模型(1.1)。此时由于(1.2)回归变量中增加的  $Y_{t-1}$  项，对于回归系数  $\alpha$  和  $\beta$  的估计往往不是应该求取的真值  $\tilde{\alpha}$  和  $\tilde{\beta}$ 。事实上，如果要求有  $\alpha = \tilde{\alpha}$  和  $\beta = \tilde{\beta}$  成立，在  $Y_t$  与  $\mathbf{X}_t$  都为平稳序列的情况下，结合

对(1.1)与(1.2)左式的等式两边求期望所得到的方程组

$$\begin{cases} E(Y_t) = \alpha + \beta^T E(\mathbf{X}_{t-1}), \\ E(Y_t) = \tilde{\alpha} + \phi E(Y_{t-1}) + \tilde{\beta}^T E(\mathbf{X}_{t-1}). \end{cases}$$

可以得到  $\phi E(Y_1) = 0$ 。由于  $\phi = 0$  等价于解释变量中不存在  $Y_{t-1}$  项, 因而由模型假设有  $\phi \neq 0$ , 即  $E(Y_1) = 0$ , 而这一条件在实际数据中往往并不符合。

对于此种内生的序列相依性的一个朴素的解决办法就是在(1.1)的左式中引入自回归项, 由此刻画响应变量内生的序列相依性。假设该式引入的自回归滞后阶数为  $p$ , 且有  $d$  个外生的解释变量, 那么该模型将有如下形式:

$$I(B)Y_t = \alpha + \beta^T \mathbf{X}_{t-1} + U_t, \quad \mathbf{X}_t = \boldsymbol{\mu} + \mathbf{A}\mathbf{X}_{t-1} + \mathbf{V}_t, \quad (1.3)$$

其中  $I(B) = 1 - \sum_{i=1}^p a_i B^i$ , 此处  $B$  表示滞后算子, 即  $BY_t = Y_{t-1}$ 。类似(1.3)左式这种带有外生变量的自回归模型又可称之为 ARX(Autoregressive Exogenous) 模型。ARX 模型的应用十分普遍, 涵盖了经济、环境、机械工程等众多领域。

对形如(1.3)的 ARX 模型进行参数拟合最常用的方法是最小二乘法, 为此我们需要对模型的随机扰动项做一系列假设以保证 OLS 估计的优良性质。该类型假设里最为经典, 同时也是较为严格的一种假设便是高斯马尔可夫假设。著名的高斯马尔可夫定理证明了在高斯马尔可夫假设下, 回归系数的 OLS 估计是最优线性无偏估计 (BLUE)。

高斯马尔可夫假设对于随机扰动项  $U_t$  的限制有零均值假定和球形扰动项假定两种, 其中球形扰动项假定又可分为同方差假定和序列无关假定。对这些假定的违背均可能带来严重的后果。如果不满足零均值假设, 则 OLS 估计的无偏性无法保证。如果不满足同方差假设或序列无关假设, 则估计不一定是有效的。简述其原理, 我们假设误差序列  $\{U_t\}_{t=1}^n$  来自于模型(1.3), 那么高斯马尔可夫假设中的球形扰动项假定可表示为对于某常数  $\sigma$ , 有  $\text{Cov}(U_1, \dots, U_n) = \sigma^2 \mathbf{I}_n$ , 其中  $\mathbf{I}_n$  表示  $n \times n$  的单位矩阵。定义回归系数  $\boldsymbol{\theta} = (\alpha, a_1, \dots, a_p, \beta^T)^T$ , 对于  $\boldsymbol{\theta}$  的 OLS 估计  $\hat{\boldsymbol{\theta}}$  以及任一无偏估计  $\tilde{\boldsymbol{\theta}}$ , 有

$$\text{Var}(\tilde{\boldsymbol{\theta}}) = \text{Var}(\hat{\boldsymbol{\theta}}) + \sigma^2 \boldsymbol{\Sigma}_{\tilde{\boldsymbol{\theta}}},$$

其中  $\boldsymbol{\Sigma}_{\tilde{\boldsymbol{\theta}}}$  为关于  $\tilde{\boldsymbol{\theta}}$  的半正定矩阵, 因此, OLS 估计  $\hat{\boldsymbol{\theta}}$  拥有  $\boldsymbol{\theta}$  的所有无偏估计中的最小方差。值得注意的是, 这一等式的成立依赖于  $(U_1, \dots, U_n)$  的协方差矩阵的单



位对角形式，因而无论是异方差性（即不存在常数  $\sigma$ ，使得  $\text{Var}(U_t) = \sigma^2$ ）还是序列相关性（即存在  $i \neq j$ ，使得  $\text{Cov}(U_i, U_j) \neq 0$ ）都会破坏  $\hat{\theta}$  的有效性，进而可能造成变量的显著性检验失效，模型预测结果不准等问题。

然而，与异方差性的存在一般只意味着 OLS 估计的有效性被破坏不同，残差序列如果表现出序列相关性可能预示着更为严重的后果。例如，我们使用模型(1.3)来拟合观测  $\{Y_t, \mathbf{X}_{t-1}\}_{t=1}^n$ ，然而生成该数据的真实模型却是

$$I(B)Y_t = \alpha + \beta^\top \mathbf{X}_{t-1} + \psi\epsilon_{t-1} + \epsilon_t, \quad \mathbf{X}_t = \boldsymbol{\mu} + \mathbf{A}\mathbf{X}_{t-1} + \mathbf{V}_t. \quad (1.4)$$

那么可以得到我们所拟合的误差项其实是  $U_t = \psi\epsilon_{t-1} + \epsilon_t$ ，假设  $\epsilon_t$  是一个白噪声序列，那么  $U_t$  服从一个 MA(1) 的分布。此时我们计算  $U_t$  的一阶序列相关，有

$$\text{Cov}(U_t U_{t-1}) = \psi \text{Var}(\epsilon_1),$$

当回归中存在显著的  $\epsilon_{t-1}$ ，即参数  $\psi$  非零时，有  $\text{Cov}(U_t U_{t-1}) \neq 0$ 。在这个例子中，造成  $U_t$  存在非零的一阶序列相关的原因是我们遗漏了  $\epsilon_{t-1}$  这一解释变量，且当  $U_t$  表现出的序列相关性越强，就预示着我们可能遗漏了越重要的解释变量。在另外的一些例子中，例如遗漏的解释变量与现有的解释变量相关，或者某些存在内生性问题的情况下，回归系数的 OLS 估计甚至可能是不一致的。这些造成误差项序列相关性的原因无一不意味着模型拟合中存在着严重的问题，即模型可能被误设了。因此，为了得到更加充分准确的拟合结果，对模型中的误差项进行序列相关检验是回归分析的重要步骤，这一步骤又可称为模型检查。

## 1.2 文献综述

### 1.2.1 ARX 模型文献综述

ARX 模型应用广泛。在金融领域，与 Stambaugh(1999)<sup>[50]</sup> 中的预测回归模型类似，ARX 模型也可用来研究外生金融变量与某种资产价格之间的联系。例如，Warsono 等 (2019)<sup>[56]</sup> 采用 VARX 模型研究了哈鲁姆能源 (HRUM) 收盘价与武吉亚三 (PTBA) 股价 (内生变量) 和汇率 (外生变量) 之间的关系。Astuti 和 Ruchjana(2017)<sup>[2]</sup> 将 ARX 模型扩展到广义空间中，并使用国际原油棕榈油 (CPO) 价格作为外生变量来预测 CPO 的出口量。

在环境领域, Bauer 等 (2001)<sup>[3]</sup> 使用不同种类的 ARX 模型分析了奥地利多个监测点收集的每小时臭氧数据, 并以此完成污染评估。除此之外还有 Chen 和 Chiu(2021)<sup>[14]</sup>, 该文使用 ARX-GARCH 模型, 利用中国东南部 16 个市县监测站的每日数据进行了空气质量水平的预测。

得益于 ARX 模型广泛的应用, 许多学者关注到 ARX 模型族的回归理论并做出了一系列工作, 内容囊括参数的与非参数的方法。枚举数例, Bierens(1990)<sup>[4]</sup> 提出了一种估计线性和非线性 ARMAX 模型参数的最小二乘方法, 并讨论了这些估计的渐近性质; Cai 和 Masry(2000)<sup>[10]</sup> 采用了结合投影的局部多项式拟合方法, 以获得非线性可加 ARX 模型的非参数估计; Wang 和 Chan(2018)<sup>[55]</sup> 引入了拟似然方法来处理删失 ARX 模型, 并证明了该拟似然方法在计算上是有效的。

尽管关于 ARX 模型的理论及实证研究已经非常丰富, 但是却鲜有文献讨论了检验其序列相关性的问题。大多数研究假设误差不存在序列相关性, 然而真实数据往往可能违背这一假设, 进而影响到研究所得出的统计推断。因此, 发展关于 ARX 模型的误差项序列相关检验理论十分重要且必要。

### 1.2.2 序列相关检验文献综述

对于误差序列是否存在自相关性的问题最为简单直观, 同时也是最早的方法便是图示法, 图示法又可主要分为趋势图观察法与自相关图观察法。趋势图观察法可简述为, 如果残差序列不存在自相关性, 那么残差序列将呈现在水平坐标轴上下以同一离散程度随机反复上下震荡的趋势。反之, 如果存在序列自相关, 其残差图将呈现一定的时序相依性。

自相关图观察法又可细分为自相关函数 (ACF) 图与偏自相关函数 (PACF) 图两种图示。该方法主要步骤是观察 ACF 与 PACF 中的各滞后阶数是否存在高于两倍标准差的值, 如若存在, 便表明在该滞后阶数上存在序列相关性。自相关图还可用于模型定阶, 其中 PACF 更加适合 AR 模型的定阶, 而 ACF 适用于 MA 模型。更多关于自相关图的讨论可参见专著 Van der Vaart(2010)<sup>[54]</sup>, Box 等 (2015)<sup>[5]</sup>, Hamilton(2020)<sup>[30]</sup>。

图示法虽然简明, 但是界定标准过于模糊, 无法适用于严肃的统计推断。致力于解决这一问题的一个开创性工作是 Durbin 和 Watson(1950)<sup>[21]</sup> 提出的 DW 检

验及其对应的 DW 检验统计量。DW 检验假设误差项符合一个一阶自回归的分布，从而将问题转化为该自回归系数是否等于 0 的参数显著性检验问题。虽然 DW 检验是序列相关检验领域一个开创性的工作，但它同时也存在诸多不足。比如它只能检验一阶的自相关，并且 DW 统计量没有一个唯一的临界值，这导致了 DW 值落在某些区间内时无法做出有效的统计推断。

DW 检验只能检验一阶自相关的不足之处被 Box 和 Pierce(1970)<sup>[8]</sup> 中提出的  $Q$  统计量得以解决。 $Q$  统计量由残差得到的自相关函数构造而成，该文证明了在零假设下，即不存在序列自相关的情况下  $Q$  统计量渐近服从自由度为检验阶数的卡方分布。在 Ljung 和 Box(1978)<sup>[40]</sup> 中， $Q$  统计量被乘上了一个权重以具备更好的小样本性质，这两种形式的  $Q$  统计量又可称为 BP 统计量与 LB 统计量。类似这样的加权版本还包括 Fisher 和 Gallagher(2012)<sup>[25]</sup> 中的版本，该版本对于  $Q$  统计量的不同阶数，即所检验的序列相关性阶数变化更加稳定。

但是 BP 检验与 LB 检验仍有许多不足之处，例如  $Q$  统计量用于检验序列相关性时，需要假设模型是强假设下的，即模型的误差项需要是 i.i.d. 的。而在弱假设下，即误差项可能并不独立且存在某种弱相关关系时， $Q$  统计量的渐近卡方性质将被破坏而使得检验失效。Romano 和 Thombs(1996)<sup>[48]</sup> 首次讨论了上述的弱假设下自相关函数与强假设下不同的渐近性质，随后该渐近分布的差异所导致的基于  $Q$  统计量的序列相关检验失效的问题也在 Francq 等 (2005)<sup>[26]</sup> 中得到讨论。随着该问题逐渐得到重视，Zhu(2016)<sup>[60]</sup> 通过导入郑忠国 (1987)<sup>[64]</sup> 中提出的随机加权法，构造了基于随机加权的自助法 (Bootstrap) $Q$  检验，并在弱假设的 ARMA 模型中获得了较好的数值结果。

而随着时间序列分析发展的进一步复杂化，多变量的 VARMA 模型族越来越多地在应用上代替了单变量的简单 ARMA 模型。为适应该发展趋势，Chitturi(1974)<sup>[17]</sup> 与 Hosking(1980, 1981)<sup>[31, 32]</sup> 等工作发展了适用于多变量时间序列模型的基于  $Q$  统计量的模型检查方法。最近的工作 Li 和 Zhang(2022)<sup>[42]</sup> 考虑到多变量情况下的弱假设问题，与 Zhu(2016)<sup>[60]</sup> 类似地引入随机加权法，构建了用于 VAR 模型的自助  $Q$  检验。最早诞生于 Box 和 Pierce(1970)<sup>[8]</sup> 与 Ljung 和 Box(1978)<sup>[40]</sup> 的  $Q$  检验在数十年之后仍有着强劲的生命力与发展势头，因为该类型的检验版本众多，适用于各种不同的假设条件、应用场景，故此类基于  $Q$  统计

量的检验方法又可称为工具箱 (Portmanteau) 检验。

除了上述种类繁多的工具箱检验, 可以应用于高阶序列相关检验方法还有 Breusch(1978)<sup>[6]</sup> 和 Godfrey(1978)<sup>[27]</sup> 提出的 BG 检验。该方法的思想是先预设误差项符合多阶的自回归模型, 并构造辅助回归模型, 然后使用拉格朗日乘数法 (Lagrange Multiplier Method, LM) 检验其中的自回归系数是否为零, 从而将误差的序列相关检验问题转化为自回归系数的参数显著性检验问题。因为该检验的关键步骤是拉格朗日乘数法, 故该方法又可称为 LM 检验。

另一类可用于序列相关检验的方法是基于经验似然 (Empirical Likelihood, EL) 的经验似然比方法。该方法比较原始的版本也是基于最小二乘残差, 比较具有代表性的工作有刘锋等 (2006)<sup>[62]</sup>, 该文将用经验似然比构造假设检验的方法应用在部分线性模型中, 其文中直接将序列残差代入经验似然函数的约束条件中的方法又可被称为插入 (Plug-in, PI) 法。类似的文献还有 Li 等 (2021)<sup>[38]</sup>, 其将刘锋等 (2006)<sup>[62]</sup> 中的检验方法推广到了函数型部分线性模型中。范雅文和刘小惠 (2019)<sup>[61]</sup> 将经验似然与刀切法 (Jackknife) 结合, 提出了预测回归模型的刀切法经验似然 (JEL) 序列相关检验, 该方法相比 PI 检验有着更好的有限样本表现。

### 1.2.3 经验似然文献综述

经验似然是一种非参数统计推断方法, 其在一般的正则条件下有比较好的统计性质。例如经典综述王启华 (2004)<sup>[63]</sup> 所总结的, 用经验似然方法构造的置信区间或置信域有域保持性, 变换不变性, 置信域的形状由数据自行决定, 无需构造轴统计量等诸多优点。此外, DiCiccio(1991)<sup>[19]</sup> 指出了经验似然法具有 Bartlett 纠偏性, 即其置信区间的覆盖率误差的收敛速度可以被提高到  $O(n^{-2})$ 。

经验似然的思想最早可以追溯到 Thomas 和 Grunkemeier(1975)<sup>[52]</sup>, 而其方法的成熟被普遍归结到 Owen(1988,1990,1991)<sup>[43, 44, 45]</sup> 等一系列工作。其中, Owen 用经验似然发展了对总体均值、线性回归模型、以及置信域的构造等经典统计推断问题的理论。Hall 和 La Scala(1990)<sup>[29]</sup> 对经验似然的算法做了比较系统的讨论。Qin 和 Jin(1994)<sup>[47]</sup> 引入了一般估计方程 (General Estimating Function) 作为经验似然用于统计推断时的限制条件, 并且提出了剖面优化经验似然方法 (Profile Empirical Likelihood) 以解决估计参数与推断参数维数不一致的问

题。Lazar(2003)<sup>[36]</sup>结合了贝叶斯思想提出了贝叶斯经验似然 (Bayesian Empirical Likelihood, BEL)。Jing 等 (2009)<sup>[33]</sup>提出了刀切法经验似然,这也是后续范雅文和刘小惠 (2019)<sup>[61]</sup>提出 JEL 序列相关检验的启发工作。最近的重要工作还有 Chang 等 (2018,2021)<sup>[13, 12]</sup>, 该文发展了惩罚经验似然方法与经验似然用于高维统计分析的理论。

经验似然方法的基础知识与基本结果大多可以在专著 Owen(2001)<sup>[46]</sup>中找到,关于回归分析方面的应用可以参见文献综述 Chen 和 Van Keilegom(2009)<sup>[15]</sup>, 应用于计量经济学与金融的综述可见 Kitamura(2006)<sup>[35]</sup>。Lazar(2021)<sup>[37]</sup>则是较近的一个综述,其中可以看到经验似然近年的发展。

### 1.3 待解决的问题与本人工作

虽然针对序列相关问题已经存在诸多检验方法,但是随着经济金融学家实证工作的不断发展,理论的不断推进,现有的方法出现了越来越多不可忽略的问题。例如, Mandelbrot(1963)<sup>[41]</sup>首次描述了经常出现于金融数据中的波动聚集现象。波动聚集现象可简略描述为,大的波动倾向于跟着大的波动,小的波动倾向于跟着小的波动,因此,波动聚集现象的存在往往预示着数据具有异方差性。为了刻画这一特性, Engle(1982)<sup>[22]</sup>和 Bollerslev(1986)<sup>[7]</sup>先后提出了 ARCH 与 GARCH 模型,该工作以二次多项式的形式构造出了一类具有条件异方差与无条件同方差的模型族。此后,以 GARCH 模型来拟合回归中的误差项成为了金融统计建模中的常见范式,常见的例子有 AR-GARCH, ARMA-GARCH 模型等。但是不幸的是,对于带有 GARCH 型误差的模型,上述的大多序列相关检验方法纷纷失效。例如以 BP 检验与 LB 检验为代表的形式比较基础的 Portmanteau 检验,其检验统计量的渐近卡方分布性质要求以误差项同方差作为假定。

除此之外还有 Stambaugh(1999)<sup>[50]</sup>中所提出的经典问题,假设数据来自于形如(1.1)的模型,其中被预测变量和预测变量各自的同期误差项  $U_t$  和  $V_t$  可能是相关的。这种相关性在有限样本的条件下可能给参数估计带来影响,进而干扰上述的基于回归残差的检验方法。例如上述经典的刘锋等 (2006)<sup>[62]</sup>中所提出的 PI 检验似然检验,就无法抵抗  $U_t$  和  $V_t$  之间的相关性对检验的破坏。

综上所述,我们需要一种可以消除数据具有异方差性和误差序列之间相关所

带来的影响的新检验方法。事实上,运用 LM 方法的 BG 检验可以抵抗上述  $U_t$  和  $V_t$  之间相关性的影响,但是其无法适用于 GARCH 误差项的序列,这也是 BP 与 LB 所共有的问题。PI 方法可以用于条件异方差序列,但是却无法忍受  $U_t$  和  $V_t$  间的相关性。鉴于适用于上述诸多条件的序列相关检验方法的缺失,本文将引入 Qin 和 Jin(1994)<sup>[47]</sup> 中的剖面优化经验似然方法,基于经验似然比构造新的检验统计量。该统计量因其计算过程为迭代优化求解的特性,检验结果明显优于上述基于最小二乘估计显式解残差的检验方法。

本文结构如下:第二章将简要介绍经验似然方法以及 Qin 和 Jin(1994)<sup>[47]</sup> 中的剖面优化经验似然方法与其他预备知识;第三章将给出本文所提出的新检验方法及其渐近性质,相关定理的理论证明,以及检验的数值模拟结果,并且将从金融和环境两个领域分别给出一个例子进行实证分析。

## 2 预备知识

在第一节中我们先定义几个本文中所使用的数学标记符号，并且叙述几个时间序列相关的定义，这些定义与标记是描述本文结果的前提。在第二节中我们叙述数个引理，分别为鞅中心极限定理、马尔科夫不等式、Delta 方法与 Cramér-Wold 定理，这些引理将用于证明本文的主要结果。

### 2.1 渐近符号及定义

本节中的定义均引用自时间序列专著 Van der Vaart(2010)<sup>[54]</sup>，或可从其中找到等价的描述。

对随机变量  $\{X_n\}_{n=1}^\infty$ ，数列  $\{a_n\}_{n=1}^\infty$ ，有：

**定义 1** (随机变量的收敛). 标记  $\xrightarrow{p}$  表示依概率收敛，标记  $\xrightarrow{d}$  表示依分布收敛。

**定义 2** (渐近阶数  $O_p$ ).  $X_n = O_p(a_n)$  表示对任意的  $\epsilon > 0$ ，存在  $N, M > 0$ ，使得当  $n > N$  时，有

$$P(|X_n/a_n| > M) < \epsilon.$$

**定义 3** (渐近阶数  $o_p$ ).  $X_n = o_p(a_n)$  表示对任意的  $\epsilon, \delta > 0$ ，存在  $N > 0$ ，使得当  $n > N$  时，有

$$P(|X_n/a_n| > \delta) < \epsilon.$$

此处**定义 1-3** 中三个关于极限过程的标记允许我们能更加便捷地描述随机变量的渐近性质。

对时间序列  $\{X_t\}_{t=1}^\infty$ ，概率空间  $(\Omega, \mathcal{F}, P)$ ，有：

**定义 4** (严平稳).  $X_t$  严平稳等价于对于任意的  $h \in \mathbb{N}$ ， $(X_t, \dots, X_{t+h})$  的联合分布独立于  $t$ 。

**定义 5** (宽平稳).  $X_t$  宽平稳等价于对于任意的  $h \in \mathbb{N}$ ， $E(X_t)$  与  $E(X_t X_{t+h})$  存在且有限，并且独立于  $t$ 。



平稳性是对时间序列而言极其关键的一个性质，非平稳的时间序列相较平稳序列在计算上复杂许多，其极限分布也更加难以探究，此外非平稳序列往往还伴随着伪回归等问题，因此，目前时间序列分析中所处理的对象基本都有平稳性这一预设条件。对平稳性的定义中，宽平稳又可称为二阶距平稳，在一、二阶距均存在的情况下，严平稳为宽平稳的充分条件。

**定义 6** (Filtration). 假设定义在  $\Omega$  上的  $\sigma$  域序列  $\{\mathcal{F}_t\}_{t=1}^{\infty}$  满足对任意的  $1 \leq i \leq j$  有  $\mathcal{F}_i \subset \mathcal{F}_j$ ，那么  $\{\mathcal{F}_t\}_{t=1}^{\infty}$  是  $(\Omega, \mathcal{F}, P)$  上的一个 Filtration，其可以理解为时刻  $t$  能获得的信息。如果对任意的  $t$  有  $\sigma(X_1, \dots, X_t) \subset \mathcal{F}_t$ ，那么称  $X_t$  是  $\mathcal{F}_t$  可测的。

**定义 7** (鞅差序列). 对于上述  $\{\mathcal{F}_t\}_{t=1}^{\infty}$ ，如果  $X_t$  是  $\mathcal{F}_t$  可测的，且满足  $E(X_t | \mathcal{F}_{t-1}) = 0$ ，那么称  $X_t$  为一关于  $\mathcal{F}_t$  的鞅差序列。

时间序列数据极少满足 i.i.d. 假设，因此我们无法使用经典的 Lindeberg–Lévy 中心极限定理来得到统计量的渐近正态性。对于这一问题，较常见的解决方法有 Strong-Mixing 中心极限定理、有限相依中心极限定理与鞅中心极限定理。这些方法的共同之处是都限制了在 (较大的) 时间间隔下，序列间的相依性应该 (逐渐) 消失。在这些方法中，鞅中心极限定理中的鞅是金融、计量经济中常用的概念，鞅差序列经常被作为对误差项的假设之一，因此，本文引入鞅与鞅中心极限定理作为方法的理论基础。

## 2.2 有关引理

**引理 1** (鞅中心极限定理). 假设  $X_t$  为一关于  $\mathcal{F}_t$  的鞅差序列，如果存在常数  $v > 0$  使得

$$\frac{1}{n} \sum_{t=1}^n E(X_t^2 | \mathcal{F}_{t-1}) \xrightarrow{p} v,$$

且对于任意  $\epsilon > 0$ ，有

$$\frac{1}{n} \sum_{t=1}^n E(X_t^2 I_{|X_t| > \epsilon \sqrt{n}} | \mathcal{F}_{t-1}) \xrightarrow{p} 0,$$

那么有

$$\sqrt{n} \bar{X}_n \xrightarrow{d} \mathcal{N}(0, v).$$

证明. 请参见专著 Van der Vaart(2010)<sup>[54]</sup> 中第 4.5 节。□

由鞅中心极限定理得到的渐近正态性是本文证明的关键, 基于该定理证明的渐近正态性是我们可以用经验似然比构造渐近服从卡方分布的检验统计量的理论基础。

**引理 2** (马尔可夫不等式). 假设  $(\Omega, \mathcal{F}, P)$  为一概率空间,  $X \in L$  为一  $\mathcal{F}$  可测实值函数, 对任意的  $\epsilon > 0$ , 有

$$P(\{\omega \in \Omega : |X(\omega)| \geq \epsilon\}) \leq \frac{1}{\epsilon} \int_{\Omega} |X| dP.$$

基于该不等式, 我们还能得到以下两条推论:

1. 假设  $(\Omega, \mathcal{F}, P)$  为一概率空间,  $X \in L$  为一  $\mathcal{F}$  可测实值函数,  $\phi$  是定义在  $\mathbb{R}^+$  上的单调递增函数, 且  $\phi \geq 0$ , 对任意满足  $\phi(\epsilon) > 0$  的  $\epsilon \geq 0$ , 有

$$P(\{\omega \in \Omega : |X(\omega)| \geq \epsilon\}) \leq \frac{1}{\phi(\epsilon)} \int_{\Omega} \phi(|X|) dP.$$

2. 假设  $(\Omega, \mathcal{F}, P)$  为一概率空间,  $X \in L^p$  为一  $\mathcal{F}$  可测实值函数, 对任意的  $\epsilon > 0$ , 有

$$P(\{\omega \in \Omega : |X(\omega)| \geq \epsilon\}) \leq \frac{1}{\epsilon^p} \int_{\Omega} |X|^p dP.$$

证明. 请参见专著 Stein 和 Shakarchi(2005)<sup>[51]</sup> 中第 91 页习题。□

本文的理论推导涉及到许多关于随机变量的渐近阶数的证明, 这是得到统计量的极限分布的基础。该工作的一个重要工具便是马尔可夫不等式及其推论, 此处我们用测度论的形式叙述该定理。

**引理 3** (Delta 方法). 定义  $f$  是一从  $\mathbb{R}^k$  到  $\mathbb{R}^m$  的函数, 且在  $\theta \in \mathbb{R}^k$  点可微。假设  $\{\mathbf{X}_n\}_{n=1}^{\infty}$  是在  $f$  的定义域上取值的随机向量, 且有趋于无穷的数列  $\{a_n\}_{n=1}^{\infty}$  与随机向量  $\mathbf{X}$ , 使得  $a_n(\mathbf{X}_n - \theta) \xrightarrow{d} \mathbf{X}$ , 那么当  $n \rightarrow \infty$  时, 有

$$a_n(f(\mathbf{X}_n) - f(\theta)) \xrightarrow{d} f'_{\theta}(\mathbf{X}),$$

$$\|a_n(f(\mathbf{X}_n) - f(\theta)) - f'_{\theta}(\mathbf{X}_n - \theta)\| = o_p(1).$$

证明. 请参见专著 Van der Vaart(2000)<sup>[53]</sup> 中第 3 章。□

Delta 方法可以理解为多元随机向量的 Taylor 展开表达式, 该方法是计算本文中经验似然比的极限分布的重要工具之一。

**引理 4** (Cramér–Wold 定理). 假设  $\{\mathbf{X}_n\}_{n=1}^\infty$  与  $\mathbf{X}$  是取值在  $\mathbb{R}^k$  上的随机向量, 那么对于任意的  $\mathbf{t} \in \mathbb{R}^k$ , 有

$$\mathbf{X}_n \xrightarrow{d} \mathbf{X} \Leftrightarrow \mathbf{t}^\top \mathbf{X}_n \xrightarrow{d} \mathbf{t}^\top \mathbf{X}.$$

证明. 请参见专著 Van der Vaart(2010)<sup>[54]</sup> 中第 3.6 节。□

Cramér–Wold 定理是沟通随机向量与随机变量的桥梁, 基于该定理我们可以轻松地由随机向量的弱收敛得到其任一线性组合的极限分布。对应本文的内容, 我们需要该定理来沟通统计量的渐近多元正态分布与渐近卡方分布。

## 2.3 经验似然方法概述

这一节我们简述经验似然方法及其用于统计推断的理论。本节内容主要来自 Owen(1988,1990,1991)<sup>[43, 44, 45]</sup> 等一系列工作, 在这些文献中 Owen 发展了经验似然的基础理论并将其应用在了均值检验、回归分析、置信域构建等经典问题上。此外, 读者也可参见专著 Owen(2001)<sup>[46]</sup> 以获得更系统的阐述。

经验似然方法的一个最基本的概念是经验分布 (Empirical Distribution), 我们以单变量随机变量为例, 假设  $X_1, \dots, X_n \in \mathbb{R}$ , 其经验分布  $F_n(x)$  为

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I_{X_i \leq x}, \quad (2.1)$$

其中  $x \in \mathbb{R}$ ,  $I_{X_i \leq x}$  为示性函数。类似于参数的似然方法, 非参数统计中也有非参数的似然函数, 即不是关于参数, 而是关于整个分布的似然函数。对  $X_1, \dots, X_n$  的任一分布  $F$ , 其非参数似然函数  $L(F)$  为

$$L(F) = \prod_{i=1}^n (F(X_i) - F(X_i-)), \quad (2.2)$$

此处  $F(X_i-)$  为  $F(x)$  在  $X_i$  处的左极限。

根据 Owen(2001)<sup>[46]</sup> 的结果, 当代入的分布为样本的经验分布时, 其非参数似然函数取得最大值, 即对  $X_1, \dots, X_n$  的任一分布  $F$ , 有  $L(F) \leq L(F_n)$ 。由此我们可以得到  $X_1, \dots, X_n$  的非参数极大似然估计即为其自身的经验分布。

类似于参数的似然方法, 经验似然中同样可以引入似然比的概念来构建置信域或假设检验。对上述的  $X_1, \dots, X_n$  以及其任一分布  $F$ , 其非参数似然比  $R(F)$  的定义为

$$R(F) = \frac{L(F)}{L(F_n)}, \quad (2.3)$$

由上我们已可知  $R(F) \leq 1$ 。假设我们感兴趣的参数是  $\theta \in \mathbb{R}^d$ , 并且存在泛函  $T$  满足  $\theta = T(F)$ , 记分布  $F$  来自分布族  $\mathcal{F}$ , 那么由泛函  $T$  可以定义经验似然函数  $\mathcal{R}(\theta)$ ,

$$\mathcal{R}(\theta) = \sup\{R(F) | \theta = T(F), F \in \mathcal{F}\}. \quad (2.4)$$

在参数的极大似然方法中, Wilks(1938)<sup>[57]</sup> 证明了由似然比可以构造出渐近服从卡方分布的统计量, 在经验似然中也由类似的结果, Owen(1988)<sup>[43]</sup> 首次证明了该非参形式的 Wilks 定理。以上述假设为例, Owen 证明的结果为, 假设  $\theta_0$  为  $\theta$  的真值, 那么

$$-2 \log \mathcal{R}(\theta_0) \xrightarrow{d} \chi_d^2, \quad (2.5)$$

此处  $\xrightarrow{d}$  表示依分布收敛,  $\chi_d^2$  为自由度为  $d$  的卡方分布。由此渐近性质, 我们得以使用经验似然来构造参数的置信域或假设检验。

## 2.4 剖面优化经验似然方法

剖面优化经验似然方法是 Qin 和 Jin(1994)<sup>[47]</sup> 中提出的对经验似然方法的一种改良。通过结合经验似然与一般估计方程, Qin 和 Jin(1994)<sup>[47]</sup> 解决了需要进行统计推断的参数个数可能少于需要进行参数估计的参数个数的问题。例如一个回归分析中常见的问题, 线性回归中需要被估计的参数至少有截距项与斜率参数两个, 但是我们可能只关心截距项是否为 0, 或者斜率参数是否显著, 此时我们预设的假设是只关于一个参数的, 但经验似然函数的计算却需要带入多个参数, 这与我们上节中介绍的方法不相符。

Qin 和 Jin(1994)<sup>[47]</sup> 对此的解决方法是, 假设参数  $\theta$  可按照我们是否感兴趣分为感兴趣的  $\theta_1 \in \mathbb{R}^{d_1}$  与冗余的  $\theta_2 \in \mathbb{R}^{d_2}$ , 即  $\theta = (\theta_1^\top, \theta_2^\top)^\top$ ,  $d = d_1 + d_2$ , 定义剖面经验似然函数  $\tilde{\mathcal{R}}(\theta_1)$  为

$$\tilde{\mathcal{R}}(\theta_1) = \sup_{\theta_2} \mathcal{R}(\theta), \quad (2.6)$$

记  $\theta_1$  的真值为  $\theta_{10}$ , 那么

$$-2 \log \tilde{\mathcal{R}}(\theta_{10}) \xrightarrow{d} \chi_{d_1}^2. \quad (2.7)$$

在应用中, 这种对经验似然函数进行剖面优化的方法不仅解决了上述的参数个数不一致的问题, 还排除了冗余参数的估计可能对统计推断的影响。例如, 以往的序列相关检验大多基于 OLS 残差, 而我们的方法将回归参数的估计过程编入经验似然的估计方程, 代入剖面经验似然方程的求解, 从而消除了 OLS 估计不准的影响, 这同时也是我们的方法为什么能优于现存的诸基于最小二乘残差的方法的原因之一, 更多细节将于第三章讨论。

### 3 ARX 模型的序列相关检验

在对时间序列数据进行模型拟合等操作之前，我们需要对其某些性质做检验，其中最重要的检验之一便是平稳性检验。平稳性对时间序列数据至关重要，对非平稳序列的回归有很大可能导致伪回归等问题。如今最常用的平稳性检验方法为 Dickey 和 Fuller(1979)<sup>[20]</sup> 与 Said 和 Dickey(1984)<sup>[49]</sup> 中提出的 DF 与 ADF 检验。在这两篇文献中，提到了在进行相关检验之前会把时间序列模型的表达式进行改写，例如(1.3)可以等价于

$$Y_t = \alpha + \phi Y_{t-1} + \sum_{i=1}^{p-1} \psi_i \Delta Y_{t-i} + \beta^\top \mathbf{X}_{t-1} + U_t, \quad \mathbf{X}_t = \boldsymbol{\mu} + \mathbf{A} \mathbf{X}_{t-1} + \mathbf{V}_t. \quad (3.1)$$

注意(1.3)中的  $I(B)$  被替换成了  $P(B) = 1 - \phi B - \sum_{i=1}^{p-1} \psi_i \Delta^i$ ，其中  $\Delta$  为差分算子，即  $\Delta Y_t = (1-B)Y_t = Y_t - Y_{t-1}$ 。简单计算可得  $\phi = \sum_{i=1}^p a_i$  与  $\psi_i = -\sum_{j=i}^{p-1} a_{j+1}$ ,  $i = 1, \dots, p-1$ 。这种改写又可称为 Dickey-Fuller 重参数化。

Dickey-Fuller 重参数化可以带来的很大一点便利就是其平稳性较为明显。在(3.1)中  $Y_t$  的内生结构的平稳性由单一参数  $\phi$  决定，而无需像在(1.3)中一样需要计算  $p$  个回归系数之和  $\sum_{i=1}^p a_i$ 。因此，我们使用(3.1)表达式进行接下来的讨论。

#### 3.1 检验方法及相关渐近性质

假设  $\{Y_t, \mathbf{X}_{t-1}\}_{t=1}^n$  是由模型(1.3)生成的观测。我们关心的是误差序列  $\{U_t\}_{t=1}^n$  中是否存在序列相关性。定义  $\gamma_k = E(U_t U_{t-k})$  且  $\boldsymbol{\gamma}^\top = (\gamma_1, \dots, \gamma_q)$ ， $q$  为一预设的常数，即检验的序列相关阶数，则假设检验问题为

$$\mathcal{H}_0 : \boldsymbol{\gamma} = \mathbf{0} \leftrightarrow \mathcal{H}_1 : \boldsymbol{\gamma} \neq \mathbf{0}.$$

既往的方法通常使用对  $U_t$  的 OLS 估计，即残差序列来估计  $\boldsymbol{\gamma}$ ，以此构建检验，上述的 DW 检验、Portmanteau 检验皆在此列。事实上，残差序列同样可以用来构造基于经验似然的检验，这种方法又可以叫做插入 (PI) 经验似然方法。该方法简述如下。

首先我们定义  $\boldsymbol{\theta} = (\alpha, \phi, \boldsymbol{\psi}^\top, \boldsymbol{\beta}^\top)^\top$ ，记其 OLS 估计为  $\hat{\boldsymbol{\theta}} := (\hat{\alpha}, \hat{\phi}, \hat{\boldsymbol{\psi}}^\top, \hat{\boldsymbol{\beta}}^\top)^\top$ ，由此我们可以通过计算  $\hat{U}_t = Y_t - \hat{\alpha} - \hat{\phi} Y_{t-1} - \sum_{i=1}^{p-1} \hat{\psi}_i \Delta Y_{t-i} - \hat{\boldsymbol{\beta}}^\top \mathbf{X}_{t-1}$  得到残差序

列  $\{\hat{U}_t\}_{t=p+q+1}^n$ 。定义  $t_0 = p + q + 1$  与  $N = n - p - q$ ，于是，PI 检验的主要步骤便是求解下列经验似然函数  $L(\gamma)$ ，

$$L(\gamma) = \sup \left\{ \prod_{t=t_0}^n Np_t : p_t \geq 0, \sum_{t=t_0}^n p_t = 1, \sum_{t=t_0}^n p_t \mathbf{Z}_t(\gamma) = 0 \right\}, \quad (3.2)$$

其中  $\mathbf{Z}_t(\gamma) = (\hat{U}_t \hat{U}_{t-1} - \gamma_1, \dots, \hat{U}_t \hat{U}_{t-q} - \gamma_q)^\top$ 。

与 Owen(1991)<sup>[45]</sup> 中证明结果类似地，此处当原假设为真，且满足一些预设条件的情况下，有  $-2 \log L(\mathbf{0})$  渐近服从卡方分布。因此，对于观测  $\{Y_t, \mathbf{X}_{t-1}\}_{t=1}^n$ ，在预设的显著性水平  $\tau \in (0, 1)$  下，我们在  $-2 \log L(\mathbf{0}) > \chi_q^2(1 - \tau)$  拒绝原假设，此处  $\chi_q^2(1 - \tau)$  表示自由度为  $q$  的卡方分布的  $(1 - \tau)$  分位点。

虽然 PI 检验计算速度较快，且能够适用于带有 GARCH 误差项的数据，但是其在上述提到的  $U_t$  和  $\mathbf{V}_t$  可能有相关性的条件下表现出较强的 Size 偏误。作为对 PI 检验的一种改进，我们结合 Qin 和 Jin(1994)<sup>[47]</sup> 中的方法提出序列相关性的剖面优化经验似然 (PEL) 检验。

首先，我们定义函数序列  $\{U_t(\boldsymbol{\theta})\}_{t=t_0}^n$  为

$$U_t(\boldsymbol{\theta}) = Y_t - \alpha - \phi Y_{t-1} - \sum_{i=1}^{p-1} \psi_i \Delta Y_{t-i} - \boldsymbol{\beta}^\top \mathbf{X}_{t-1}, \quad (3.3)$$

从而定义一个新的关于  $\boldsymbol{\theta}$  与  $\gamma$  两个参数的经验似然函数，

$$\tilde{L}(\boldsymbol{\theta}, \gamma) = \sup \left\{ \prod_{t=t_0}^n Np_t : p_t \geq 0, \sum_{t=t_0}^n p_t = 1, \sum_{t=t_0}^n p_t \tilde{\mathbf{Z}}_t(\boldsymbol{\theta}, \gamma) = 0 \right\}, \quad (3.4)$$

其中  $\tilde{\mathbf{Z}}_t(\boldsymbol{\theta}, \gamma) = (\tilde{Z}_{t,1}(\boldsymbol{\theta}, \gamma), \tilde{Z}_{t,2}(\boldsymbol{\theta}, \gamma), \dots, \tilde{Z}_{t,p+d+q+1}(\boldsymbol{\theta}, \gamma))^\top$ ,

$$\begin{cases} \tilde{Z}_{t,1}(\boldsymbol{\theta}, \gamma) &= U_t(\boldsymbol{\theta}), \\ \tilde{Z}_{t,2}(\boldsymbol{\theta}, \gamma) &= U_t(\boldsymbol{\theta}) Y_{t-1}, \\ \tilde{Z}_{t,j+2}(\boldsymbol{\theta}, \gamma) &= U_t(\boldsymbol{\theta}) \Delta Y_{t-j}, \quad j = 1, 2, \dots, p-1, \\ \tilde{Z}_{t,p+l+1}(\boldsymbol{\theta}, \gamma) &= U_t(\boldsymbol{\theta}) X_{t-1,l}, \quad l = 1, 2, \dots, d, \\ \tilde{Z}_{t,p+d+k+1}(\boldsymbol{\theta}, \gamma) &= U_t(\boldsymbol{\theta}) U_{t-k}(\boldsymbol{\theta}) - \gamma_k, \quad k = 1, 2, \dots, q. \end{cases}$$

这里  $X_{t-1,l}$  表示  $\mathbf{X}_{t-1}$  的第  $l$  个元素。

我们需要进行检验的参数是  $\gamma$ , 参照前章(2.6)的内容, 我们可以将(3.3)中的参数  $\theta$  视为冗余参数对其进行优化, 得到最终的剖面优化经验似然函数  $\mathcal{L}(\gamma)$ ,

$$\mathcal{L}(\gamma) = \sup_{\theta} \tilde{L}(\theta, \gamma). \quad (3.5)$$

在讨论  $\mathcal{L}(\gamma)$  的渐近性质之前, 我们首先需要进行以下的假设:

- **A1.**  $\{\mathbf{X}_t\}$  为一严平稳序列,  $\{\mathbf{X}_0\}$  为一常向量。
- **A2.**  $\{U_t, \mathbf{V}_t\}_{t=1}^n$  是对于  $\text{Filtration}\{\mathcal{F}_t = \sigma(U_s, \mathbf{V}_s : s \leq t)\}_{t=1}^n$  的鞅差序列。
- **A3.**  $E(U_t^2) = \sigma_U^2, E(V_{t,1}^2) = \sigma_{V_1}^2, \dots, E(V_{t,d}^2) = \sigma_{V_d}^2$  几乎处处成立。
- **A4.** 对于某  $\delta > 0$ ,  $\sup_{t \geq 1} E(|U_t|^{2+\delta} + |V_{t,1}|^{2+\delta} + \dots + |V_{t,d}|^{2+\delta}) < \infty$  几乎处处成立。
- **A5.**  $|\phi| < 1$  且  $1 - \sum_{i=1}^{p-1} \psi_i x^i = 0$  的根都在单位圆内。

在假设 **A1-A5** 下, 我们可以得到本文的主要结果:

**定理 1.** 假设 **A1-A5** 成立, 那么当原假设  $\mathcal{H}_0$  为真且  $n \rightarrow \infty$  时, 有

$$-2 \log \mathcal{L}(\mathbf{0}) \xrightarrow{d} \chi_q^2.$$

由该渐近卡方的性质, 对于一个预设的显著性水平  $\tau \in (0, 1)$ , 我们在满足

$$-2 \log \mathcal{L}(\mathbf{0}) > \chi_q^2(1 - \tau)$$

的条件下拒绝原假设。

## 3.2 数值模拟

在本节中我们将生成模拟数据来检验所提方法的效果, 即对于 ARX 模型的 PEL 序列相关检验。同时, 我们还将对比其他两种现存的检验方法, 分别是 PI 检验与 BG 检验。首先, 我们预设两种  $U_t$  的数据生成过程 (DGP), 分别为(3.6)与(3.7)。假设  $\{e_t\}_{t=1}^n$  是随机生成的独立同分布正态分布的样本, 该两种 DGP 为

$$U_t = \lambda U_{t-1} + e_t, \quad (3.6)$$

$$U_t = \eta_t \sigma_t, \quad \sigma_t^2 = 0.01 + 0.32 U_{t-1}^2 + 0.23 \sigma_{t-1}^2, \quad \eta_t = \frac{\lambda e_{t-1} + e_t}{\sqrt{1 + \lambda^2}}. \quad (3.7)$$



式(3.6)中的  $U_t$  的序列相关性来自于简单的 AR(1) 结构中非零的  $\lambda$ , 而(3.7)中的 GARCH(1,1) 模型则描述了一个相对复杂的异方差结构。当  $\lambda = 0$  时, 该情况对应于检验的 Size。考虑到检验该方法的局部 Power, 我们设定  $\lambda = 1/\sqrt{n}, \dots, 4/\sqrt{n}$ 。

$U_t$  与  $V_t$  之间的相关性的设计由向量  $\boldsymbol{\rho} = (\rho_1, \dots, \rho_d)^\top$  实现。该向量决定了  $U_t$  与  $V_t$  的联合分布的协方差矩阵。该设计的细节为

$$\begin{pmatrix} e_t \\ \mathbf{V}_t \end{pmatrix} \sim \mathcal{N}(0, \boldsymbol{\Gamma}), \quad \boldsymbol{\Gamma} = \begin{bmatrix} 1 & \rho_1 & \rho_2 & \cdots & \rho_{d-1} & \rho_d \\ \rho_1 & 1 & 0 & \cdots & 0 & 0 \\ \rho_2 & 0 & 1 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ \rho_{d-1} & 0 & 0 & \cdots & 1 & 0 \\ \rho_d & 0 & 0 & \cdots & 0 & 1 \end{bmatrix},$$

可以看到, 对于  $1 \leq t \leq n, 1 \leq k \leq d$ , 有  $\text{Cov}(U_t, V_{t,k}) = \rho_k$ ; 对于  $1 \leq t \leq n, 1 \leq k \neq l \leq d$ , 有  $\text{Cov}(V_{t,k}, V_{t,l}) = 0$ 。

为了不将模拟试验设计得太过复杂, 我们假设考虑的 ARX 模型的 DGP 为

$$Y_t = \alpha + \phi Y_{t-1} + \psi \Delta Y_{t-1} + \beta X_{t-1} + U_t, \quad X_t = \mu + A X_{t-1} + V_t. \quad (3.8)$$

外生变量  $X_t$  自身的截距项与关于  $Y_t$  的斜率系数设置为两个常数, 分别为  $\mu = 0.01$  与  $\beta = 2.14$ 。差分项  $\Delta Y_{t-1}$  的斜率系数为  $\psi = 0.13$ 。 $\alpha$  假设为 0 与 0.01, 以此来刻画  $Y_t$  是否存在截距项的两种情况。对于自回归系数  $\phi$  与  $A$ , 分别都设定有 0.6 与 1 两种情况来对应平稳序列与单位根过程。 $U_t$  和  $V_t$  的协方差  $\rho$  有 0, 0.4, 0.8 三种设定, 分别表示无相关性、弱相关性、强相关性三种情况。序列长度  $n$  的设置为 200 与 800。对于上述的每种情况, 我们生成 10000 个样本。

模拟试验中 PEL 检验和 PI 检验的经验似然函数的编程借助了 R 包 “emplik” 中的函数 “el.test”。PEL 检验中的剖面优化使用了 R 函数 “nlm”。BG 检验的结果来自于现有 R 函数 “bg.test”。我们在表 3.1 - 3.6 与图 3.1 - 3.6 中展示 PEL, PI, BG 三种检验的结果。

表 3.1 - 3.3 展示了 AR 结构的  $U_t$  的 Size 和 Power。正如我们所预期的, 本文提出的 PEL 检验在所有的设定情况下都有着不错的检验功效。对于部分设定, 例如当  $\phi$  与  $A$  都等于 1 的时候, 即  $X_t$  与  $Y_t$  的内生 AR 结构都为非平稳的时候, 样

本量  $n = 200$  的情况下 Size 有着轻微的过大失真，但是当样本量增大到 800 时，所有的经验 Size 都收敛到了预设的显著性水平  $\tau$ 。值得注意的在该表的情况下 BG 检验也有着不错的表现，即对于 AR 结构的  $U_t$ ，即使  $U_t$  与  $V_t$  之间存在较强的相关性也不影响 BG 检验的有效性。然而，PI 检验的 Size 因为  $Y_t$  的内生自回归结构表现出了明显的过小失真。与包括 BP，LB 检验的 Portmanteau 检验类似，PI 检验也依赖回归变量外生的假定，否则检验统计量的渐近性质将受内生变量的影响而趋于复杂，故 PI 检验其实并不适用于 ARX 模型。

表 3.4 - 3.6 展示了 GARCH 结构的  $U_t$  的 Size 和 Power。值得注意与表 3.1 - 3.3 有明显不同的是，此处 BG 检验的结果相比预设的显著性水平  $\tau$  偏离严重，这意味着随机误差项的异方差结构使得 BG 检验完全失效了。而对于 PI 检验，可以看出其在异方差情况下还是部分有效的。观察本表上半部分  $\rho = 0$  与  $\rho = 0.4$  的情况，可以看到 PI 检验的 Size 在  $U_t$  之间的  $V_t$  相关性还不太强的时候是接近预设的显著性水平的，但是当该相关性逐渐增强，甚至接近 1 时，PI 检验会遭受严重的过小的 Size 偏离，而这种程度的相关性是经常能在实际数据中找到的。与上述两种方法形成强烈对比的是，PEL 检验在这些复杂情况下依然大体保持稳健。不过依然需要指出的是，在小样本的情况下，对应表中  $n = 200$  的结果，PEL 检验的结果还是有可见的过度拒绝现象，但是这些偏差随着样本量的增加而收敛趋于零。另外，当  $X_t$  和  $Y_t$  都是非平稳序列时，对应于表中  $\phi = A = 1$  的情况，以及同时  $U_t$  与  $V_t$  强相关时，PEL 检验的 Size 还是会有不可忽视的过度拒绝，即使是在样本量为 800 时也仍未完全消失。

模拟试验的部分结果绘制为图 3.1 - 3.6。前两幅图分别展示了 PEL 检验在 AR 结构与 GARCH 结构误差项下的结果，对比可以发现，其在 GARCH 条件下经验拒绝概率随  $\lambda$  增加而增加的速度不如 AR 条件，然而检验本身还是表现良好。观察图 3.3 与 3.4，可以看到 PI 检验在较小的  $\rho$  的条件下，即  $U_t$  与  $V_t$  之间的相关性不太强时表现良好，但当  $\rho$  过大时面临失效，这与上述表格的描述一致。对于最后两张图 3.5 和 3.6，可以看到 BG 检验在 AR 的误差结构下的所有情况下都表现良好，但是无法适用于 GARCH 结构的误差。

表 3.1: AR 结构误差项的经验 Size 和 Power

| $(\rho, \phi, A, \lambda)$           | $\alpha = 0$ |        |        |        |        |        | $\alpha = 0.01$ |        |        |        |        |        |
|--------------------------------------|--------------|--------|--------|--------|--------|--------|-----------------|--------|--------|--------|--------|--------|
|                                      | $n = 200$    |        |        |        |        |        | $n = 800$       |        |        |        |        |        |
|                                      | PEL          | PI     | BG     | PEL    | PI     | BG     | PEL             | PI     | BG     | PEL    | PI     | BG     |
| (0, 0.6, 0.6, 0)                     | 0.0596       | 0.0348 | 0.0579 | 0.0480 | 0.0311 | 0.0508 | 0.0620          | 0.0371 | 0.0534 | 0.0513 | 0.0316 | 0.0507 |
| (0, 0.6, 0.6, $\frac{2}{\sqrt{n}}$ ) | 0.3657       | 0.2867 | 0.3600 | 0.4042 | 0.3191 | 0.4019 | 0.3617          | 0.2775 | 0.3597 | 0.4052 | 0.3137 | 0.3980 |
| (0, 0.6, 0.6, $\frac{4}{\sqrt{n}}$ ) | 0.9163       | 0.8760 | 0.9236 | 0.9423 | 0.9092 | 0.9389 | 0.9175          | 0.8782 | 0.9186 | 0.9387 | 0.9003 | 0.9332 |
| (0, 1, 0.6, 0)                       | 0.0583       | 0.0410 | 0.0538 | 0.0528 | 0.0359 | 0.0486 | 0.0593          | 0.0406 | 0.0545 | 0.0534 | 0.0323 | 0.0494 |
| (0, 1, 0.6, $\frac{2}{\sqrt{n}}$ )   | 0.3498       | 0.3056 | 0.3582 | 0.4075 | 0.3460 | 0.4131 | 0.3575          | 0.3045 | 0.3567 | 0.4177 | 0.3483 | 0.4115 |
| (0, 1, 0.6, $\frac{4}{\sqrt{n}}$ )   | 0.8400       | 0.8919 | 0.9132 | 0.8354 | 0.9195 | 0.9417 | 0.9214          | 0.8910 | 0.9151 | 0.9212 | 0.9261 | 0.9411 |
| (0, 1, 1, 0)                         | 0.0626       | 0.0391 | 0.0536 | 0.0497 | 0.0359 | 0.0505 | 0.0672          | 0.0421 | 0.0562 | 0.0529 | 0.0345 | 0.0560 |
| (0, 1, 1, $\frac{2}{\sqrt{n}}$ )     | 0.3741       | 0.3097 | 0.3521 | 0.4169 | 0.3601 | 0.4120 | 0.3815          | 0.3050 | 0.3450 | 0.4207 | 0.3619 | 0.4170 |
| (0, 1, 1, $\frac{4}{\sqrt{n}}$ )     | 0.8943       | 0.8928 | 0.9174 | 0.9267 | 0.9284 | 0.9476 | 0.8876          | 0.8964 | 0.9222 | 0.9238 | 0.9278 | 0.9436 |

表 3.2: AR 结构误差项的经验 Size 和 Power

| $(\rho, \phi, A, \lambda)$             | $\alpha = 0$ |        |        |        |        |        | $\alpha = 0.01$ |        |        |        |        |        |
|----------------------------------------|--------------|--------|--------|--------|--------|--------|-----------------|--------|--------|--------|--------|--------|
|                                        | $n = 200$    |        |        |        |        |        | $n = 800$       |        |        |        |        |        |
|                                        | PEL          | PI     | BG     | PEL    | PI     | BG     | PEL             | PI     | BG     | PEL    | PI     | BG     |
| (0.4, 0.6, 0.6, 0)                     | 0.0571       | 0.0333 | 0.0577 | 0.0496 | 0.0304 | 0.0507 | 0.0573          | 0.0369 | 0.0545 | 0.0510 | 0.0330 | 0.0497 |
| (0.4, 0.6, 0.6, $\frac{2}{\sqrt{n}}$ ) | 0.3660       | 0.3002 | 0.3632 | 0.4081 | 0.3361 | 0.4062 | 0.3732          | 0.3052 | 0.3627 | 0.4041 | 0.3423 | 0.4011 |
| (0.4, 0.6, 0.6, $\frac{4}{\sqrt{n}}$ ) | 0.9112       | 0.8807 | 0.9155 | 0.9355 | 0.9082 | 0.9374 | 0.9070          | 0.8764 | 0.9141 | 0.9393 | 0.9086 | 0.9392 |
| (0.4, 1, 0.6, 0)                       | 0.0594       | 0.0421 | 0.0499 | 0.0511 | 0.0389 | 0.0531 | 0.0583          | 0.0437 | 0.0514 | 0.0513 | 0.0363 | 0.0496 |
| (0.4, 1, 0.6, $\frac{2}{\sqrt{n}}$ )   | 0.3661       | 0.3273 | 0.3715 | 0.4209 | 0.3747 | 0.4243 | 0.3580          | 0.3309 | 0.3735 | 0.4215 | 0.3734 | 0.4178 |
| (0.4, 1, 0.6, $\frac{4}{\sqrt{n}}$ )   | 0.8368       | 0.8986 | 0.9182 | 0.9233 | 0.9333 | 0.9485 | 0.8303          | 0.8974 | 0.9150 | 0.9250 | 0.9298 | 0.9443 |
| (0.4, 1, 1, 0)                         | 0.0678       | 0.0567 | 0.0520 | 0.0494 | 0.0535 | 0.0486 | 0.0657          | 0.0596 | 0.0513 | 0.0530 | 0.0511 | 0.0514 |
| (0.4, 1, 1, $\frac{2}{\sqrt{n}}$ )     | 0.4387       | 0.4227 | 0.4246 | 0.4790 | 0.4782 | 0.4682 | 0.4390          | 0.4275 | 0.4127 | 0.4753 | 0.4727 | 0.4665 |
| (0.4, 1, 1, $\frac{4}{\sqrt{n}}$ )     | 0.9156       | 0.9596 | 0.9607 | 0.9497 | 0.9720 | 0.9701 | 0.9181          | 0.9555 | 0.9574 | 0.9454 | 0.9738 | 0.9728 |

表 3.3: AR 结构误差项的经验 Size 和 Power

| $(\rho, \phi, A, \lambda)$             | $\alpha = 0$ |        |        |           |        |        | $\alpha = 0.01$ |        |        |           |        |        |
|----------------------------------------|--------------|--------|--------|-----------|--------|--------|-----------------|--------|--------|-----------|--------|--------|
|                                        | $n = 200$    |        |        | $n = 800$ |        |        | $n = 200$       |        |        | $n = 800$ |        |        |
|                                        | PEL          | PI     | BG     | PEL       | PI     | BG     | PEL             | PI     | BG     | PEL       | PI     | BG     |
| (0.8, 0.6, 0.6, 0)                     | 0.0532       | 0.0089 | 0.0567 | 0.0538    | 0.0057 | 0.0495 | 0.0544          | 0.0074 | 0.0516 | 0.0502    | 0.0059 | 0.0531 |
| (0.8, 0.6, 0.6, $\frac{2}{\sqrt{n}}$ ) | 0.2378       | 0.0703 | 0.2359 | 0.2577    | 0.0787 | 0.2535 | 0.2376          | 0.0677 | 0.2253 | 0.2560    | 0.075  | 0.2717 |
| (0.8, 0.6, 0.6, $\frac{4}{\sqrt{n}}$ ) | 0.6951       | 0.4030 | 0.6907 | 0.7485    | 0.4426 | 0.7544 | 0.6938          | 0.3900 | 0.6909 | 0.7519    | 0.4463 | 0.7538 |
| (0.8, 1, 0.6, 0)                       | 0.0569       | 0.0088 | 0.0516 | 0.0525    | 0.0076 | 0.0487 | 0.0521          | 0.0102 | 0.0539 | 0.0498    | 0.0073 | 0.0512 |
| (0.8, 1, 0.6, $\frac{2}{\sqrt{n}}$ )   | 0.2359       | 0.0747 | 0.2316 | 0.2676    | 0.0880 | 0.2744 | 0.2422          | 0.0787 | 0.2436 | 0.2745    | 0.0839 | 0.2684 |
| (0.8, 1, 0.6, $\frac{4}{\sqrt{n}}$ )   | 0.6691       | 0.4528 | 0.7067 | 0.7700    | 0.4867 | 0.7752 | 0.6730          | 0.4425 | 0.7066 | 0.7623    | 0.4950 | 0.7653 |
| (0.8, 1, 1, 0)                         | 0.0616       | 0.0245 | 0.0550 | 0.0516    | 0.0201 | 0.0507 | 0.0604          | 0.0211 | 0.0587 | 0.0513    | 0.0193 | 0.0519 |
| (0.8, 1, 1, $\frac{2}{\sqrt{n}}$ )     | 0.3501       | 0.2263 | 0.3254 | 0.3708    | 0.2424 | 0.3566 | 0.3445          | 0.2251 | 0.3293 | 0.3688    | 0.2348 | 0.3648 |
| (0.8, 1, 1, $\frac{4}{\sqrt{n}}$ )     | 0.8719       | 0.8202 | 0.8896 | 0.8999    | 0.8254 | 0.9021 | 0.8679          | 0.8205 | 0.8917 | 0.8968    | 0.8266 | 0.9056 |

表 3.4: GARCH 结构误差项的经验 Size 和 Power

| $(\rho, \phi, A, \lambda)$           | $\alpha = 0$ |        |        |        |        |        | $\alpha = 0.01$ |        |        |        |        |        |
|--------------------------------------|--------------|--------|--------|--------|--------|--------|-----------------|--------|--------|--------|--------|--------|
|                                      | $n = 200$    |        |        |        |        |        | $n = 800$       |        |        |        |        |        |
|                                      | PEL          | PI     | BG     | PEL    | PI     | BG     | PEL             | PI     | BG     | PEL    | PI     | BG     |
| (0, 0.6, 0.6, 0)                     | 0.0653       | 0.0647 | 0.1416 | 0.0560 | 0.0556 | 0.1632 | 0.0658          | 0.0622 | 0.1419 | 0.0542 | 0.0544 | 0.1622 |
| (0, 0.6, 0.6, $\frac{2}{\sqrt{n}}$ ) | 0.3660       | 0.3813 | 0.5544 | 0.3794 | 0.3929 | 0.6183 | 0.3707          | 0.3796 | 0.5599 | 0.3734 | 0.4039 | 0.6146 |
| (0, 0.6, 0.6, $\frac{4}{\sqrt{n}}$ ) | 0.7632       | 0.8689 | 0.9621 | 0.7591 | 0.8986 | 0.9759 | 0.7583          | 0.8702 | 0.9626 | 0.7594 | 0.9056 | 0.9754 |
| (0, 1, 0.6, 0)                       | 0.0658       | 0.0612 | 0.1508 | 0.0598 | 0.0526 | 0.1537 | 0.0656          | 0.0620 | 0.1386 | 0.0575 | 0.0520 | 0.1607 |
| (0, 1, 0.6, $\frac{2}{\sqrt{n}}$ )   | 0.3486       | 0.3651 | 0.5393 | 0.3756 | 0.3983 | 0.6106 | 0.3391          | 0.3622 | 0.5406 | 0.3785 | 0.3811 | 0.6046 |
| (0, 1, 0.6, $\frac{4}{\sqrt{n}}$ )   | 0.6795       | 0.8602 | 0.9516 | 0.7192 | 0.9018 | 0.9745 | 0.6867          | 0.8672 | 0.9595 | 0.7205 | 0.9079 | 0.9760 |
| (0, 1, 1, 0)                         | 0.0735       | 0.0625 | 0.1473 | 0.0593 | 0.0557 | 0.1631 | 0.074           | 0.0644 | 0.1462 | 0.0565 | 0.0547 | 0.1628 |
| (0, 1, 1, $\frac{2}{\sqrt{n}}$ )     | 0.3847       | 0.3627 | 0.5322 | 0.3795 | 0.3876 | 0.6067 | 0.3943          | 0.3628 | 0.5384 | 0.3931 | 0.3917 | 0.6019 |
| (0, 1, 1, $\frac{4}{\sqrt{n}}$ )     | 0.8440       | 0.8639 | 0.9536 | 0.7583 | 0.9049 | 0.9770 | 0.8441          | 0.8553 | 0.9570 | 0.7547 | 0.8957 | 0.9767 |

表 3.5: GARCH 结构误差项的经验 Size 和 Power

| $(\rho, \phi, A, \lambda)$             | $\alpha = 0$ |        |        |           |        |        | $\alpha = 0.01$ |        |        |           |        |        |
|----------------------------------------|--------------|--------|--------|-----------|--------|--------|-----------------|--------|--------|-----------|--------|--------|
|                                        | $n = 200$    |        |        | $n = 800$ |        |        | $n = 200$       |        |        | $n = 800$ |        |        |
|                                        | PEL          | PI     | BG     | PEL       | PI     | BG     | PEL             | PI     | BG     | PEL       | PI     | BG     |
| (0.4, 0.6, 0.6, 0)                     | 0.0701       | 0.0436 | 0.1410 | 0.0531    | 0.0364 | 0.1524 | 0.0654          | 0.0428 | 0.1395 | 0.0525    | 0.038  | 0.1570 |
| (0.4, 0.6, 0.6, $\frac{2}{\sqrt{n}}$ ) | 0.3449       | 0.2963 | 0.5106 | 0.3707    | 0.3024 | 0.5733 | 0.3458          | 0.2924 | 0.5083 | 0.3626    | 0.3064 | 0.5684 |
| (0.4, 0.6, 0.6, $\frac{4}{\sqrt{n}}$ ) | 0.7459       | 0.7970 | 0.9408 | 0.7363    | 0.8424 | 0.9654 | 0.7414          | 0.8002 | 0.9412 | 0.7420    | 0.8442 | 0.9633 |
| (0.4, 1, 0.6, 0)                       | 0.0705       | 0.0437 | 0.1379 | 0.0629    | 0.0338 | 0.1526 | 0.0619          | 0.0456 | 0.1404 | 0.0634    | 0.0398 | 0.1631 |
| (0.4, 1, 0.6, $\frac{2}{\sqrt{n}}$ )   | 0.3239       | 0.2936 | 0.4983 | 0.3598    | 0.3038 | 0.5659 | 0.3175          | 0.2895 | 0.4991 | 0.3626    | 0.3042 | 0.5616 |
| (0.4, 1, 0.6, $\frac{4}{\sqrt{n}}$ )   | 0.6694       | 0.7881 | 0.9342 | 0.7100    | 0.8444 | 0.9620 | 0.6619          | 0.7910 | 0.9348 | 0.7104    | 0.8379 | 0.9608 |
| (0.4, 1, 1, 0)                         | 0.0792       | 0.0495 | 0.1408 | 0.0621    | 0.0426 | 0.1637 | 0.0769          | 0.0500 | 0.1389 | 0.0598    | 0.0401 | 0.1524 |
| (0.4, 1, 1, $\frac{2}{\sqrt{n}}$ )     | 0.3608       | 0.2868 | 0.4990 | 0.3765    | 0.3153 | 0.5691 | 0.3714          | 0.2909 | 0.4915 | 0.3715    | 0.3173 | 0.5611 |
| (0.4, 1, 1, $\frac{4}{\sqrt{n}}$ )     | 0.8265       | 0.7967 | 0.9373 | 0.7412    | 0.8532 | 0.9609 | 0.8196          | 0.7959 | 0.9344 | 0.7477    | 0.8532 | 0.9620 |

表 3.6: GARCH 结构误差项的经验 Size 和 Power

| $(\rho, \phi, A, \lambda)$             | $\alpha = 0$ |        |        |           |        |        | $\alpha = 0.01$ |        |        |           |        |        |
|----------------------------------------|--------------|--------|--------|-----------|--------|--------|-----------------|--------|--------|-----------|--------|--------|
|                                        | $n = 200$    |        |        | $n = 800$ |        |        | $n = 200$       |        |        | $n = 800$ |        |        |
|                                        | PEL          | PI     | BG     | PEL       | PI     | BG     | PEL             | PI     | BG     | PEL       | PI     | BG     |
| (0.8, 0.6, 0.6, 0)                     | 0.0644       | 0.0028 | 0.1120 | 0.0513    | 0.0019 | 0.1370 | 0.0632          | 0.0020 | 0.1131 | 0.0584    | 0.0018 | 0.1364 |
| (0.8, 0.6, 0.6, $\frac{2}{\sqrt{n}}$ ) | 0.2097       | 0.0266 | 0.3061 | 0.2104    | 0.0226 | 0.3634 | 0.2217          | 0.0269 | 0.2982 | 0.2116    | 0.0251 | 0.3609 |
| (0.8, 0.6, 0.6, $\frac{4}{\sqrt{n}}$ ) | 0.5523       | 0.1972 | 0.6954 | 0.5658    | 0.1944 | 0.7821 | 0.5376          | 0.1961 | 0.6979 | 0.5608    | 0.1956 | 0.7789 |
| (0.8, 1, 0.6, 0)                       | 0.0654       | 0.0035 | 0.1147 | 0.0677    | 0.0029 | 0.1340 | 0.0670          | 0.0031 | 0.1174 | 0.0696    | 0.0021 | 0.1413 |
| (0.8, 1, 0.6, $\frac{2}{\sqrt{n}}$ )   | 0.2050       | 0.0285 | 0.2935 | 0.2282    | 0.0235 | 0.3548 | 0.2089          | 0.0311 | 0.2983 | 0.2281    | 0.0227 | 0.3572 |
| (0.8, 1, 0.6, $\frac{4}{\sqrt{n}}$ )   | 0.5008       | 0.1909 | 0.6842 | 0.5693    | 0.1922 | 0.7783 | 0.4951          | 0.1909 | 0.6875 | 0.5831    | 0.1941 | 0.7781 |
| (0.8, 1, 1, 0)                         | 0.0886       | 0.0030 | 0.1205 | 0.0701    | 0.0033 | 0.1344 | 0.0804          | 0.0034 | 0.1253 | 0.0717    | 0.0024 | 0.1379 |
| (0.8, 1, 1, $\frac{2}{\sqrt{n}}$ )     | 0.2579       | 0.0333 | 0.2998 | 0.2469    | 0.0311 | 0.3683 | 0.2527          | 0.0316 | 0.2950 | 0.2440    | 0.0281 | 0.3679 |
| (0.8, 1, 1, $\frac{4}{\sqrt{n}}$ )     | 0.6173       | 0.2238 | 0.7013 | 0.6097    | 0.2353 | 0.7940 | 0.6122          | 0.2156 | 0.7030 | 0.6139    | 0.2279 | 0.7993 |






图 3.1: PEL 检验在 AR 结构的误差项下的经验拒绝率




图 3.2: PEL 检验在 GARCH 结构的误差项下的经验拒绝率




图 3.3: PI 检验在 AR 结构的误差项下的经验拒绝率




图 3.4: PI 检验在 GARCH 结构的误差项下的经验拒绝率




图 3.5: BG 检验在 AR 结构的误差项下的经验拒绝率




图 3.6: BG 检验在 GARCH 结构的误差项下的经验拒绝率

### 3.3 理论证明

本节将证明上述的定理 1, 为此我们需要先证明数个引理。记  $\boldsymbol{\theta}_0$  与  $\boldsymbol{\gamma}_0$  为  $\boldsymbol{\gamma}$  与  $\boldsymbol{\gamma}$  的真值。在原假设为真时, 有  $\boldsymbol{\gamma}_0 = \mathbf{0}$ 。另外, 因为不影响极限性质的证明, 本文不区别  $n$  与  $N$  的使用。

**引理 5.** 在假设 **A1-A5** 下, 当  $n \rightarrow \infty$  时, 有

$$\max_{t_0 \leq t \leq n} \sup_{\boldsymbol{\theta} \in \mathcal{B}} \|\tilde{\mathbf{Z}}_t(\boldsymbol{\theta}, \boldsymbol{\gamma}_0)\| = o_p(\sqrt{n}), \quad (3.9)$$

$$\frac{1}{\sqrt{n}} \sum_{t=t_0}^n \tilde{\mathbf{Z}}_t(\boldsymbol{\theta}, \boldsymbol{\gamma}_0) = \frac{1}{\sqrt{n}} \sum_{t=t_0}^n \tilde{\mathbf{Z}}_t(\boldsymbol{\theta}_0, \boldsymbol{\gamma}_0) + O_p(1), \quad (3.10)$$

$$\frac{1}{n} \sum_{t=t_0}^n \tilde{\mathbf{Z}}_t(\boldsymbol{\theta}, \boldsymbol{\gamma}_0) \tilde{\mathbf{Z}}_t^\top(\boldsymbol{\theta}, \boldsymbol{\gamma}_0) = \frac{1}{n} \sum_{t=t_0}^n \tilde{\mathbf{Z}}_t(\boldsymbol{\theta}_0, \boldsymbol{\gamma}_0) \tilde{\mathbf{Z}}_t^\top(\boldsymbol{\theta}_0, \boldsymbol{\gamma}_0) + o_p(1), \quad (3.11)$$

此处  $\mathcal{B} = \{\boldsymbol{\theta} : \|\boldsymbol{\theta} - \boldsymbol{\theta}_0\| < \frac{C}{\sqrt{n}}\}$ ,  $C > 0$  为某常数。

**证明.** 简便起见我们定义  $U_t = U_t(\boldsymbol{\theta}_0)$ 。作为展示(3.9)的渐近性质的第一步, 我们先展开  $\tilde{\mathbf{Z}}_t(\boldsymbol{\theta}, \boldsymbol{\gamma}_0)$  的第一个元素:

$$\tilde{Z}_{t,1}(\boldsymbol{\theta}, \boldsymbol{\gamma}_0) = U_t - (\alpha - \alpha_0) - (\phi - \phi_0)Y_{t-1} - \sum_{i=1}^{p-1} (\psi_i - \psi_{i0})\Delta Y_{t-i} - (\boldsymbol{\beta} - \boldsymbol{\beta}_0)^\top \mathbf{X}_{t-1},$$

当  $n \rightarrow \infty$  时, 有

$$\begin{aligned} \max_{t_0 \leq t \leq n} \sup_{\mathcal{B}} |\tilde{Z}_{t,1}(\boldsymbol{\theta}, \boldsymbol{\gamma}_0)| &\leq \max_{t_0 \leq t \leq n} |U_t| + O\left(\frac{1}{\sqrt{n}}\right) \times \left( \max_{t_0 \leq t \leq n} |Y_{t-1}| \right. \\ &\quad \left. + \max_{t_0 \leq t \leq n} \sum_{i=1}^{p-1} |\Delta Y_{t-i}| + \max_{t_0 \leq t \leq n} \|\mathbf{X}_{t-1}\| \right). \end{aligned}$$

由假设 **A4** 和马尔可夫不等式, 我们可以得到  $\max_{t_0 \leq t \leq n} |U_t| = o_p(\sqrt{n})$ 。同理对于  $\max_{t_0 \leq t \leq n} |Y_{t-1}|$ ,  $\max_{t_0 \leq t \leq n} \sum_{i=1}^{p-1} |\Delta Y_{t-i}|$ ,  $\max_{t_0 \leq t \leq n} \|\mathbf{X}_{t-1}\|$ , 我们也可以证明它们是  $o_p(\sqrt{n})$ 。以  $\max_{t_0 \leq t \leq n} |Y_{t-1}|$  为例, 对于任意的  $\epsilon > 0$  与  $\delta > 0$ , 当  $n \rightarrow \infty$  时, 有

$$\begin{aligned} P\left(\max_{t_0 \leq t \leq n} |Y_{t-1}| \geq \epsilon \sqrt{n}\right) &\leq \sum_{t=t_0}^n P(|Y_{t-1}| \geq \epsilon \sqrt{n}) \\ &\leq \frac{1}{\epsilon^{2+\delta} n^{1+\delta/2}} E\left(\sum_{t=t_0}^n |Y_{t-1}|^{2+\delta}\right) \\ &\rightarrow 0. \end{aligned}$$

同理可以得到另外两项的相似结论, 进而有  $\max_{t_0 \leq t \leq n} \sup_B |\tilde{Z}_{t,1}(\boldsymbol{\theta}, \boldsymbol{\gamma}_0)| = o_p(\sqrt{n})$ 。基于该结果, 对  $j = 2, \dots, p+d+1$ , 可以类似地得到  $\max_{t_0 \leq t \leq n} \sup_B |\tilde{Z}_{t,j}(\boldsymbol{\theta}, \boldsymbol{\gamma}_0)| = o_p(\sqrt{n})$ , 此处省略, 而只展示后  $q$  项。即, 对  $k = 1, \dots, q$ , 有

$$\begin{aligned} \tilde{Z}_{t,p+d+k+1}(\boldsymbol{\theta}, \boldsymbol{\gamma}_0) &= U_t(\boldsymbol{\theta})U_{t-k}(\boldsymbol{\theta}) \\ &= U_t U_{t-k} + U_t(U_{t-k}(\boldsymbol{\theta}) - U_{t-k}) + (U_t(\boldsymbol{\theta}) - U_t)U_{t-k} \\ &\quad + (U_t(\boldsymbol{\theta}) - U_t)(U_{t-k}(\boldsymbol{\theta}) - U_{t-k}) \\ &:= B_1 + B_2 + B_3 + B_4, \end{aligned}$$

其中  $U_t(\boldsymbol{\theta}) - U_t = (\alpha - \alpha_0) + (\phi - \phi_0)Y_{t-1} + \sum_{i=1}^{p-1}(\psi_i - \psi_{i0})\Delta Y_{t-i} + (\boldsymbol{\beta} - \boldsymbol{\beta}_0)^\top \mathbf{X}_{t-1}$ 。证明对于  $i = 1, 2, 3$  有  $\max_{t_0 \leq t \leq n} |B_i| = o_p(\sqrt{n})$  的细节被包括在证明对于  $i = 4$  的相关结果中, 所以我们此处仅展开  $B_4$ :

$$\begin{aligned} B_4 &= (\alpha - \alpha_0)^2 + (\alpha - \alpha_0)(\phi - \phi_0)Y_{t-1} + (\alpha - \alpha_0) \sum_{i=1}^{p-1} (\psi_i - \psi_{i0})\Delta Y_{t-i} \\ &\quad + (\alpha - \alpha_0)(\boldsymbol{\beta} - \boldsymbol{\beta}_0)^\top \mathbf{X}_{t-1} + (\alpha - \alpha_0)(\phi - \phi_0)Y_{t-1} + (\phi - \phi_0)^2 Y_{t-1}^2 \\ &\quad + (\phi - \phi_0)Y_{t-1} \sum_{i=1}^{p-1} (\psi_i - \psi_{i0})\Delta Y_{t-i} + (\phi - \phi_0)Y_{t-1}(\boldsymbol{\beta} - \boldsymbol{\beta}_0)^\top \mathbf{X}_{t-1} \\ &\quad + (\alpha - \alpha_0) \sum_{i=1}^{p-1} (\psi_i - \psi_{i0})\Delta Y_{t-i} + (\phi - \phi_0)Y_{t-1} \sum_{i=1}^{p-1} (\psi_i - \psi_{i0})\Delta Y_{t-i} \\ &\quad + \left( \sum_{i=1}^{p-1} (\psi_i - \psi_{i0})\Delta Y_{t-i} \right)^2 + (\boldsymbol{\beta} - \boldsymbol{\beta}_0)^\top \mathbf{X}_{t-1} \sum_{i=1}^{p-1} (\psi_i - \psi_{i0})\Delta Y_{t-i} \\ &\quad + (\alpha - \alpha_0)(\boldsymbol{\beta} - \boldsymbol{\beta}_0)^\top \mathbf{X}_{t-1} + (\phi - \phi_0)Y_{t-1}(\boldsymbol{\beta} - \boldsymbol{\beta}_0)^\top \mathbf{X}_{t-1} \\ &\quad + (\boldsymbol{\beta} - \boldsymbol{\beta}_0)^\top \mathbf{X}_{t-1} \sum_{i=1}^{p-1} (\psi_i - \psi_{i0})\Delta Y_{t-i} + (\boldsymbol{\beta} - \boldsymbol{\beta}_0)^\top \mathbf{X}_{t-1} \mathbf{X}_{t-1}^\top (\boldsymbol{\beta} - \boldsymbol{\beta}_0). \end{aligned}$$

根据上述基于马尔可夫不等式的证明技巧, 不难发现对于从  $t_0$  到  $n$  的  $t$ ,  $B_4$  的展开项中的最大值是  $o_p(\sqrt{n})$ 。因此我们可以得到(3.9)的结论。

下一步, 对于  $j = 1, 2, \dots, p+d+1$ , 当  $n \rightarrow \infty$  时,

$$\frac{1}{\sqrt{n}} \sum_{t=t_0}^n \left( \tilde{Z}_{t,j}(\boldsymbol{\theta}, \boldsymbol{\gamma}_0) - \tilde{Z}_{t,j}(\boldsymbol{\theta}_0, \boldsymbol{\gamma}_0) \right) = O_p(1)$$

的证明显然易见。因此，我们仅展示(3.10)中后  $q$  项的细节。即对于  $k = 1, \dots, q$ ，有

$$\begin{aligned}
 & \frac{1}{\sqrt{n}} \sum_{t=t_0}^n \left( \tilde{Z}_{t,k}(\boldsymbol{\theta}, \gamma_0) - \tilde{Z}_{t,k}(\boldsymbol{\theta}_0, \gamma_0) \right) \\
 &= \frac{1}{\sqrt{n}} \sum_{t=t_0}^n \left( U_t(\boldsymbol{\theta}) U_{t-k}(\boldsymbol{\theta}) - U_t U_{t-k} \right) \\
 &= \frac{1}{\sqrt{n}} \sum_{t=t_0}^n \left( U_t(U_{t-k}(\boldsymbol{\theta}) - U_{t-k}) + (U_t(\boldsymbol{\theta}) - U_t)U_{t-k} + (U_t(\boldsymbol{\theta}) - U_t)(U_{t-k}(\boldsymbol{\theta}) - U_{t-k}) \right) \\
 &= \frac{1}{\sqrt{n}} \sum_{t=t_0}^n B_2 + \frac{1}{\sqrt{n}} \sum_{t=t_0}^n B_3 + \frac{1}{\sqrt{n}} \sum_{t=t_0}^n B_4 \\
 &:= C_1 + C_2 + C_3.
 \end{aligned}$$

接着，我们展开  $C_1$ ，

$$\begin{aligned}
 C_1 &= \frac{1}{\sqrt{n}}(\alpha - \alpha_0) \sum_{t=t_0}^n U_{t-k} + \frac{1}{\sqrt{n}}(\phi - \phi_0) \sum_{t=t_0}^n Y_{t-1} U_{t-k} \\
 &\quad + \frac{1}{\sqrt{n}} \sum_{i=1}^{p-1} (\psi_i - \psi_{i0}) \sum_{t=t_0}^n \Delta Y_{t-i} U_{t-k} + \frac{1}{\sqrt{n}}(\boldsymbol{\beta} - \boldsymbol{\beta}_0) \sum_{t=t_0}^n \mathbf{X}_{t-1} U_{t-k} \\
 &= O_p(1).
 \end{aligned}$$

相似地，易得当  $n \rightarrow \infty$  时，有  $C_2, C_3 = O_p(1)$ ，由此我们结束了(3.10)的证明。(3.11)的证明相比(3.10)没有额外的部分需要讨论，此处省略。□

**引理 6.** 在假设 **A1-A5** 下，当  $\mathcal{H}_0$  为真且  $n \rightarrow \infty$  时，有

$$\frac{1}{\sqrt{n}} \sum_{t=t_0}^n \tilde{\mathbf{Z}}_t(\boldsymbol{\theta}_0, \mathbf{0}) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma}), \quad (3.12)$$

$$\frac{1}{n} \sum_{t=t_0}^n \tilde{\mathbf{Z}}_t(\boldsymbol{\theta}_0, \mathbf{0}) \tilde{\mathbf{Z}}_t^\top(\boldsymbol{\theta}_0, \mathbf{0}) \xrightarrow{p} \boldsymbol{\Sigma}, \quad (3.13)$$

此处  $\xrightarrow{d}$  表示依分布收敛， $\xrightarrow{p}$  表示依概率收敛，下同。定义矩阵  $\boldsymbol{\Sigma}$  代表  $E\left(\tilde{\mathbf{Z}}_t(\boldsymbol{\theta}_0, \mathbf{0}) \tilde{\mathbf{Z}}_t^\top(\boldsymbol{\theta}_0, \mathbf{0})\right)$ ，其为一正定阵。

**证明.** 根据假设 **A2**，显然可见  $\{\tilde{\mathbf{Z}}_t(\boldsymbol{\theta}, \gamma)\}_{t=t_0}^n$  是关于  $\mathcal{F}_{t-1}$  的鞅差序列。基于假设 **A1-A5**，由 Hall 和 Heyde(2014)<sup>[28]</sup> 中的鞅中心极限定理与 Cramér-Wold 定理可得(3.12)。同理可得(3.13)。□

定理 1 的证明. 基于引理 5 与引理 6 的结果, 我们最终可以证明所提检验统计量的渐近卡方性. 根据 Owen(2001)<sup>[46]</sup> 中的结果,  $p_t$  基于拉格朗日乘数法的解为

$$p_t = \frac{1}{n} \frac{1}{1 + \boldsymbol{\lambda}^\top \tilde{\mathbf{Z}}_t(\boldsymbol{\theta}, \gamma_0)}, \quad t = t_0, \dots, n.$$

注意其经验似然函数中的估计方程要求  $\sum_{t=t_0}^n p_t \tilde{\mathbf{Z}}_t(\boldsymbol{\theta}, \gamma_0) = 0$ , 定义

$$\mathbf{g}(\boldsymbol{\theta}, \gamma, \mathbf{x}) := \frac{1}{n} \sum_{t=t_0}^n \frac{\tilde{\mathbf{Z}}_t(\boldsymbol{\theta}, \gamma)}{1 + \mathbf{x}^\top \tilde{\mathbf{Z}}_t(\boldsymbol{\theta}, \gamma)}, \text{ and}$$

$$\xi_t(\boldsymbol{\theta}, \gamma_0) := \boldsymbol{\lambda}^\top \tilde{\mathbf{Z}}_t(\boldsymbol{\theta}, \gamma_0),$$

其中  $\boldsymbol{\lambda}$  是  $\mathbf{g}(\boldsymbol{\theta}, \gamma, \mathbf{x}) = 0$  对于某固定  $\boldsymbol{\theta}$  关于  $\mathbf{x}$  的解。

首先, 我们证明当  $n \rightarrow \infty$  有  $\|\boldsymbol{\lambda}\| = O_p\left(\frac{1}{\sqrt{n}}\right)$ 。定义  $\rho = \|\boldsymbol{\lambda}\|$ , 假设向量  $\mathbf{v}$  满足  $\boldsymbol{\lambda} = \rho \mathbf{v}$ 。我们将根据  $\|\mathbf{g}(\boldsymbol{\theta}, \gamma_0, \boldsymbol{\lambda})\| = 0$  证明上述结果。参设参数  $\boldsymbol{\theta} \in \mathcal{B}$ , 那么有

$$\begin{aligned} 0 &= \|\boldsymbol{\lambda}^\top \mathbf{g}(\boldsymbol{\theta}, \gamma_0, \boldsymbol{\lambda})\| \\ &= \left| \frac{1}{n} \sum_{t=t_0}^n \xi_t(\boldsymbol{\theta}, \gamma_0) - \frac{1}{n} \sum_{t=t_0}^n \frac{\xi_t^2(\boldsymbol{\theta}, \gamma_0)}{1 + \xi_t(\boldsymbol{\theta}, \gamma_0)} \right| \\ &\geq \left| \frac{1}{n} \sum_{t=t_0}^n \frac{\xi_t^2(\boldsymbol{\theta}, \gamma_0)}{1 + \xi_t(\boldsymbol{\theta}, \gamma_0)} \right| - \left| \frac{1}{n} \sum_{t=t_0}^n \xi_t(\boldsymbol{\theta}, \gamma_0) \right| \\ &\geq \frac{1}{n} \sum_{t=t_0}^n \frac{\xi_t^2(\boldsymbol{\theta}, \gamma_0)}{1 + \max_{t_0 \leq t \leq n} \xi_t(\boldsymbol{\theta}, \gamma_0)} - \left| \frac{1}{n} \sum_{t=t_0}^n \xi_t(\boldsymbol{\theta}, \gamma_0) \right|. \end{aligned}$$

简便起见, 我们定义

$$\mathbf{D}_n(\boldsymbol{\theta}) = \frac{1}{\sqrt{n}} \sum_{t=t_0}^n \tilde{\mathbf{Z}}_t(\boldsymbol{\theta}, \gamma_0), \quad \mathbf{F}_n(\boldsymbol{\theta}) = \frac{1}{n} \sum_{t=t_0}^n \tilde{\mathbf{Z}}_t(\boldsymbol{\theta}, \gamma_0) \tilde{\mathbf{Z}}_t^\top(\boldsymbol{\theta}, \gamma_0),$$

于是上述的不等式可以写为

$$\begin{aligned} \rho^2 \mathbf{v}^\top \mathbf{F}_n(\boldsymbol{\theta}) \mathbf{v} &\leq \left| \frac{1}{n} \sum_{t=t_0}^n \xi_t(\boldsymbol{\theta}, \gamma_0) \right| \left( 1 + \max_{t_0 \leq t \leq n} \xi_t(\boldsymbol{\theta}, \gamma_0) \right) \\ &\leq \left( \left| \frac{\rho}{n} \sum_{t=t_0}^n \mathbf{v}^\top \tilde{\mathbf{Z}}_t(\boldsymbol{\theta}_0, \gamma_0) \right| + \left| \frac{\rho}{n} \sum_{t=t_0}^n \mathbf{v}^\top (\tilde{\mathbf{Z}}_t(\boldsymbol{\theta}, \gamma_0) - \tilde{\mathbf{Z}}_t(\boldsymbol{\theta}_0, \gamma_0)) \right| \right) \\ &\quad \times \left( 1 + |\rho| \max_{t_0 \leq t \leq n} \left| \mathbf{v}^\top \tilde{\mathbf{Z}}_t(\boldsymbol{\theta}, \gamma_0) \right| \right) \\ &= |\rho| \times O_p\left(\frac{1}{\sqrt{n}}\right) + \rho^2 \times O_p\left(\frac{1}{\sqrt{n}}\right) \times o_p(\sqrt{n}). \end{aligned}$$

注意其中  $\mathbf{F}_n(\boldsymbol{\theta}) \xrightarrow{p} \boldsymbol{\Sigma}$ , 并且由于  $\boldsymbol{\Sigma}$  是正定阵,  $\mathbf{v}^\top \mathbf{F}_n(\boldsymbol{\theta}) \mathbf{v}$  要大于  $\mathbf{F}_n(\boldsymbol{\theta}) = \boldsymbol{\Sigma} + o_p(1)$  的最小特征值, 从而  $\|\boldsymbol{\lambda}\| = O_p\left(\frac{1}{\sqrt{n}}\right)$  得证。

下一步, 我们证明对于  $\boldsymbol{\theta} \in \mathcal{B}$  有

$$\boldsymbol{\lambda} = \frac{1}{\sqrt{n}} \left( \boldsymbol{\Sigma}^{-1} \mathbf{D}_n(\boldsymbol{\theta}) + o_p(1) \right). \quad (3.14)$$

根据估计方程  $\sum_{t=t_0}^n p_t \tilde{\mathbf{Z}}_t(\boldsymbol{\theta}, \gamma_0) = 0$ , 可得

$$\begin{aligned} 0 &= \mathbf{g}(\boldsymbol{\theta}, \gamma_0, \boldsymbol{\lambda}) \\ &= \frac{1}{n} \sum_{t=t_0}^n \left( \tilde{\mathbf{Z}}_t(\boldsymbol{\theta}, \gamma) \frac{1 - \xi_t^2(\boldsymbol{\theta}, \gamma) + \xi_t^2(\boldsymbol{\theta}, \gamma)}{1 + \xi_t(\boldsymbol{\theta}, \gamma)} \right) \\ &= \frac{1}{n} \sum_{t=t_0}^n \left( \tilde{\mathbf{Z}}_t(\boldsymbol{\theta}, \gamma) (1 - \xi_t(\boldsymbol{\theta}, \gamma)) \right) + \frac{1}{n} \sum_{t=t_0}^n \left( \tilde{\mathbf{Z}}_t(\boldsymbol{\theta}, \gamma) \frac{\xi_t^2(\boldsymbol{\theta}, \gamma)}{1 + \xi_t(\boldsymbol{\theta}, \gamma)} \right) \\ &= \frac{1}{\sqrt{n}} \mathbf{D}_n(\boldsymbol{\theta}) + \boldsymbol{\Sigma} \boldsymbol{\lambda} + \frac{1}{n} \sum_{t=t_0}^n \left( \tilde{\mathbf{Z}}_t(\boldsymbol{\theta}, \gamma) \frac{\xi_t^2(\boldsymbol{\theta}, \gamma)}{1 + \xi_t(\boldsymbol{\theta}, \gamma)} \right). \end{aligned}$$

由上述结论有

$$\max_{t_0 \leq t \leq n} \xi_t(\boldsymbol{\theta}, \gamma_0) \leq |\rho| \max_{t_0 \leq t \leq n} \left| \mathbf{v}^\top \tilde{\mathbf{Z}}_t(\boldsymbol{\theta}, \gamma_0) \right| = O_p \left( \frac{1}{\sqrt{n}} \right) \times o_p(\sqrt{n}) = o_p(1),$$

故我们可以进一步得到

$$\begin{aligned} &\left\| \frac{1}{n} \sum_{t=t_0}^n \left( \tilde{\mathbf{Z}}_t(\boldsymbol{\theta}, \gamma_0) \frac{\xi_t^2(\boldsymbol{\theta}, \gamma_0)}{1 + \xi_t(\boldsymbol{\theta}, \gamma_0)} \right) \right\| \\ &= \left\| \boldsymbol{\lambda}^\top \frac{1}{n} \sum_{t=t_0}^n \left( \tilde{\mathbf{Z}}_t(\boldsymbol{\theta}, \gamma_0) \tilde{\mathbf{Z}}_t^\top(\boldsymbol{\theta}, \gamma_0) \frac{\xi_t(\boldsymbol{\theta}, \gamma_0)}{1 + \xi_t(\boldsymbol{\theta}, \gamma_0)} \right) \right\| \\ &= O_p \left( \frac{1}{\sqrt{n}} \right) \times o_p(1) = o_p \left( \frac{1}{\sqrt{n}} \right). \end{aligned}$$

这一结论再一次运用了  $\mathbf{F}_n(\boldsymbol{\theta})$  的正定性。此处我们证明了(3.14)式。

最后我们证明所提检验统计量的渐近分布。此处我们泰勒展开  $-2 \log \tilde{L}(\boldsymbol{\theta}, \gamma_0)$ ,



$\zeta_t$  表示 0 与  $\xi_t(\boldsymbol{\theta}, \gamma_0)$  间的某一点,

$$\begin{aligned}
 & -2 \log \tilde{L}(\boldsymbol{\theta}, \gamma_0) \\
 = & 2 \sum_{t=t_0}^n \xi_t(\boldsymbol{\theta}, \gamma_0) - \sum_{t=t_0}^n \xi_t^2(\boldsymbol{\theta}, \gamma_0) + \sum_{t=t_0}^n \frac{2}{3(1+\zeta_t)^3} \xi_t^3(\boldsymbol{\theta}, \gamma_0) \\
 = & 2\sqrt{n}\boldsymbol{\lambda}^\top \left( \frac{1}{\sqrt{n}} \sum_{t=t_0}^n \tilde{\mathbf{Z}}_t(\boldsymbol{\theta}, \gamma_0) \right) + \sum_{t=t_0}^n \frac{2}{3(1+\zeta_t)^3} \xi_t^3(\boldsymbol{\theta}, \gamma_0) \\
 & - n\boldsymbol{\lambda}^\top \left( \frac{1}{n} \sum_{t=t_0}^n \tilde{\mathbf{Z}}_t(\boldsymbol{\theta}, \gamma_0) \tilde{\mathbf{Z}}_t^\top(\boldsymbol{\theta}, \gamma_0) \right) \boldsymbol{\lambda} \\
 = & 2 \left( \mathbf{D}_n^\top(\boldsymbol{\theta}) \boldsymbol{\Sigma}^{-1} + o_p(1) \right) \mathbf{D}_n(\boldsymbol{\theta}) + \sum_{t=t_0}^n \frac{2}{3(1+\zeta_t)^3} \xi_t^3(\boldsymbol{\theta}, \gamma_0) \\
 & - \left( \mathbf{D}_n^\top(\boldsymbol{\theta}) \boldsymbol{\Sigma}^{-1} + o_p(1) \right) \mathbf{F}_n(\boldsymbol{\theta}) \left( \mathbf{D}_n(\boldsymbol{\theta}) \boldsymbol{\Sigma}^{-1} + o_p(1) \right) \\
 = & \mathbf{D}_n^\top(\boldsymbol{\theta}) \boldsymbol{\Sigma}^{-1} \mathbf{D}_n(\boldsymbol{\theta}) + o_p(1).
 \end{aligned}$$

注意对于某常数  $C > 0$ , 有

$$\begin{aligned}
 \left| \sum_{t=t_0}^n \frac{2}{3(1+\zeta_t)^3} \xi_t^3(\boldsymbol{\theta}, \gamma_0) \right| & \leq C \max_{t_0 \leq t \leq n} \xi_t(\boldsymbol{\theta}, \gamma_0) \sum_{t=t_0}^n \xi_t^2(\boldsymbol{\theta}, \gamma_0) \\
 & = C \max_{t_0 \leq t \leq n} \xi_t(\boldsymbol{\theta}, \gamma_0) \sum_{t=t_0}^n \boldsymbol{\lambda}^\top \mathbf{F}_n(\boldsymbol{\theta}) \boldsymbol{\lambda} \\
 & = o_p(1).
 \end{aligned}$$

假设矩阵  $\mathbf{B}_n(\boldsymbol{\theta})$  是以下方程的解,

$$\mathbf{D}_n(\boldsymbol{\theta}) - \mathbf{D}_n(\boldsymbol{\theta}_0) = \mathbf{B}_n(\boldsymbol{\theta})(\boldsymbol{\theta} - \boldsymbol{\theta}_0),$$

注意  $\mathbf{B}_n(\boldsymbol{\theta})$  是一个分块为零的分块矩阵, 即  $\mathbf{B}_n(\boldsymbol{\theta}) = \begin{pmatrix} \mathbf{B}_n^*(\boldsymbol{\theta}) \\ \mathbf{0}_{q \times (p+d+q+1)} \end{pmatrix}$ ,  $\mathbf{0}_{x \times y}$  表示  $x \times y$  的零矩阵。假设  $\tilde{\boldsymbol{\theta}}$  是以下目标函数的解, 即  $\tilde{\boldsymbol{\theta}} := \arg \min_{\boldsymbol{\theta}} G(\boldsymbol{\theta})$ , 其中

$$\begin{aligned}
 G(\boldsymbol{\theta}) & = -2 \log \tilde{L}(\boldsymbol{\theta}, \gamma_0) + 2 \log \tilde{L}(\boldsymbol{\theta}_0, \gamma_0) \\
 & = \mathbf{D}_n^\top(\boldsymbol{\theta}) \boldsymbol{\Sigma}^{-1} \mathbf{D}_n(\boldsymbol{\theta}) - \mathbf{D}_n^\top(\boldsymbol{\theta}_0) \boldsymbol{\Sigma}^{-1} \mathbf{D}_n(\boldsymbol{\theta}_0) + o_p(1) \\
 & = (\boldsymbol{\theta} - \boldsymbol{\theta}_0)^\top \mathbf{B}_n^\top(\boldsymbol{\theta}) \boldsymbol{\Sigma}^{-1} \mathbf{B}_n(\boldsymbol{\theta})(\boldsymbol{\theta} - \boldsymbol{\theta}_0) + 2(\boldsymbol{\theta} - \boldsymbol{\theta}_0)^\top \mathbf{B}_n^\top(\boldsymbol{\theta}) \boldsymbol{\Sigma}^{-1} \mathbf{D}_n(\boldsymbol{\theta}_0) + o_p(1).
 \end{aligned}$$

根据 Owen(2001)<sup>[46]</sup> 中证明的相关结果, 有  $\inf_{\mathcal{B}} G(\boldsymbol{\theta}) = G(\boldsymbol{\theta}_0) = 0$ 。解  $G(\boldsymbol{\theta}) = 0$ , 可以得到

$$(\tilde{\boldsymbol{\theta}} - \boldsymbol{\theta}_0) = - \left( \mathbf{B}_n^\top(\tilde{\boldsymbol{\theta}}) \boldsymbol{\Sigma}^{-1} \mathbf{B}_n(\tilde{\boldsymbol{\theta}}) \right)^{-1} \boldsymbol{\Sigma}^{-1} \mathbf{D}_n(\boldsymbol{\theta}_0) + o_p(1).$$

由上述结果, 我们可以证明所提的 PEL 检验统计量是渐近服从卡方分布的。假设  $n \rightarrow \infty$ , 有

$$\begin{aligned} & -2 \log \tilde{L}(\tilde{\boldsymbol{\theta}}, \gamma_0) \\ &= \mathbf{D}_n^\top(\tilde{\boldsymbol{\theta}}) \boldsymbol{\Sigma}^{-1} \mathbf{D}_n(\tilde{\boldsymbol{\theta}}) + o_p(1) \\ &= \left( \mathbf{B}_n(\tilde{\boldsymbol{\theta}})(\tilde{\boldsymbol{\theta}} - \boldsymbol{\theta}_0) + \mathbf{D}_n(\boldsymbol{\theta}_0) \right)^\top \boldsymbol{\Sigma}^{-1} \left( \mathbf{B}_n(\tilde{\boldsymbol{\theta}})(\tilde{\boldsymbol{\theta}} - \boldsymbol{\theta}_0) + \mathbf{D}_n(\boldsymbol{\theta}_0) \right) + o_p(1) \\ &= \left( \boldsymbol{\Sigma}^{-\frac{1}{2}} \mathbf{D}_n(\tilde{\boldsymbol{\theta}}) \right)^\top \left( \mathbf{I}_{p+d+q+1} - \boldsymbol{\Sigma}^{\frac{1}{2}} \mathbf{B}_n(\tilde{\boldsymbol{\theta}}) \left( \mathbf{B}_n^\top(\tilde{\boldsymbol{\theta}}) \boldsymbol{\Sigma}^{-1} \mathbf{B}_n(\tilde{\boldsymbol{\theta}}) \right)^{-1} \mathbf{B}_n^{-1}(\tilde{\boldsymbol{\theta}}) \boldsymbol{\Sigma}^{\frac{1}{2}} \right) \\ & \quad \left( \boldsymbol{\Sigma}^{-\frac{1}{2}} \mathbf{D}_n(\tilde{\boldsymbol{\theta}}) \right) + o_p(1) \\ &= \left( \boldsymbol{\Sigma}^{-\frac{1}{2}} \mathbf{D}_n(\tilde{\boldsymbol{\theta}}) \right)^\top \begin{pmatrix} \mathbf{0}_{(p+d+1) \times (p+d+1)} & \mathbf{0}_{(p+d+1) \times q} \\ \mathbf{0}_{(p+d+1) \times q} & \mathbf{I}_q \end{pmatrix} \left( \boldsymbol{\Sigma}^{-\frac{1}{2}} \mathbf{D}_n(\tilde{\boldsymbol{\theta}}) \right) + o_p(1) \xrightarrow{d} \chi_q^2. \end{aligned}$$

□

### 3.4 实证研究

本节运用所提 PEL 方法在金融与环境两个领域进行实证研究。在以下两个小节中, 我们分别对两组数据进行 ARX 模型拟合与 PEL 序列相关检验, 随后将得到的结果与现存的 PI 检验、BG 检验比较分析。结果表明本文所提方法在部分情况下得到了与现存方法不同的结论, 而这些结论与一些最近的实证研究所得出的新发现相符合。这表明基于 PEL 检验的模型检查方法使得我们得以进行更加贴近事实的统计推断。

#### 3.4.1 股票收益数据分析

如本文引言所提到的, 资产价格 (如股价、投资组合等) 是否能被其他金融变量所预测 (如股息率、市盈率等) 是经济金融领域研究的一大重点。经典文献 Campbell 和 Yogo(2006)<sup>[11]</sup> 对美国股市数据进行了可预测性检验, 他们的研究结

论是,有确切证据表明市盈率、国债利率和股票收益利差可以被用来预测股价,而股息率对于股指的可预测性较弱。此外,Francq 和 Zakoïuan(2005)<sup>[26]</sup> 与 Zhu 等(2014)<sup>[59]</sup> 的研究也认为,对于股票收益的线性建模 ARMA(1,1) 是合适的,本文使用该结论,将股票收益自身的一阶滞后设定为一个解释变量。

在本节中,我们应用新提出的 PEL 方法重新审视 Campbell 和 Yogo(2006)<sup>[11]</sup> 所分析的美国股票数据。本节所使用的数据有两个来源,分别为全球金融数据(Global Financial Data)网站上的月度标普 500(S&P500) 指数和来自美国证券价格研究中心(Center for Research in Security Prices, CRSP) 的月度加权 CRSP 指数(参见图 3.7)。




图 3.7: CRSP 和 S&P500 趋势图

与 Campbell 和 Yogo(2006)<sup>[11]</sup> 所进行的分析方式类似,本文使用股票收益作为被预测变量,并且考虑三个样本时间段,分别为 1927 至 2002 年;1927 至 1994 年;1952 至 2002 年。此种分割样本的方式主要是因为在 1994 年前后,估值比降到了历史低位,使得数据序列趋于非平稳,以及 1952 年的美联储锚定利率政策使得美国利率的内在逻辑发生了根本改变。对于前两种时间段,即 1927 至 2002 年与 1927 至 1994 年,我们仅添加两种外生变量,分别为对数市盈率(Log Earnings-Price Ratio, LEP) 与对数股息率(Log Dividend-Price Ratio, LDP)。市盈率的计算方法是过去十年收益的平均除以当前价格,股息率的计算方法是过去一年的股息除以当前价格。在 1952 至 2002 年这一样本时间段中,我们额外添加两个用于

预测的外生变量，分别为国债利率 (Treasury-Bill Rates, TBL) 与股票的长期收益利差 (Long-Term Yield Spread, LTY)。此处使用的长期收益利差数据来自于穆迪 Aaa 级企业债券利率。最后，如上文所述，我们使用被预测变量自身，即股票收益率的一阶滞后作为一个预测变量。记  $t$  时刻的股票收益率为  $Y_t$ ，则 1927 至 2002 年与 1927 至 1994 年拟合的 ARX 模型可记为(3.15)，1952 至 2002 年所拟合的可记为(3.16)。

$$Y_t = \alpha + \phi Y_{t-1} + \beta_1 LEP_{t-1} + \beta_2 LDP_{t-1} + U_t, \quad (3.15)$$

$$Y_t = \alpha + \phi Y_{t-1} + \beta_1 LEP_{t-1} + \beta_2 LDP_{t-1} + \beta_3 TBL_{t-1} + \beta_4 LTY_{t-1} + U_t. \quad (3.16)$$

在进行 ARX 模型拟合之前，我们先遵从 Campbell 和 Yogo(2006)<sup>[11]</sup> 中的方法对数据进行基于预测回归模型的建模，预测回归模型的形式可参见(1.1)左式。随后我们运用本文所提的 PEL 方法检验误差的序列相关性。表 3.7 展示了检验结果的 P 值。可以看到，尽管 Campbell 和 Yogo(2006)<sup>[11]</sup> 文中论证了对数市盈率用以预测股票收益率的合理性，但是我们的 PEL 检验得到了在 0.1 的显著性水平下拒绝原假设的结果，即认为该模型的误差项存在序列相关性，也就表明模型的设置可能有误，或者存在例如缺失其他重要解释变量这样的不完善之处。因此，使用该模型得到的时间序列数据预测是无法保证其准确性的。

接下来，我们在预测回归模型的基础上加上股票收益率的一阶滞后作为一个解释变量，并且考虑外生变量的向量形式，即考虑(3.15)与(3.16)的模型形式进行回归。随后我们分别使用 PEL, PI, BG 方法进行误差项的序列相关检验，相关结果展示在表 3.8 中。可以看到，在 0.05 的显著性水平下，PEL 方法对所有考虑到的时间段与模型形式都做出了接受原假设的推断。对比表 3.7 中 PEL 在 1927 至 2002 年和 1927 至 1994 年两个时间段拒绝原假设，即否定预测回归模型拟合效果的结果，可以说明，对于预测回归模型(1.1)到 ARX 模型(1.3)的改进是十分有效的，可以认为同时带有内生自回归项与多个外生变量的模型(3.15)用于拟合或预测相关时间段的股票收益率数据是充分、有效的。

PI 检验在 0.05 的显著性水平下得出了与 PEL 一致的结论，然而，PI 检验结果的 P 值都相当高，这应该是因为  $U_t$  和  $V_t$  之间的强相关性导致的。回顾表 3.1 - 3.6，PI 检验模拟结果的经验拒绝率随着  $\rho$  增加而逐渐减小，说明  $U_t$  和  $V_t$  之间的相关性越强，PI 检验统计量的分布相比标准卡方就将越左偏，这与此处得到的

极高 P 值的结果是相符的。事实上，我们对拟合得到的  $U_t$  和  $V_t$  残差序列进行了 Pearson 相关检验，其结果都在 0.95 以上，说明该两个序列的确是高度相关的。

而对于 BG 检验，其在 1927 至 2002 年和 1927 至 1994 年两个样本时间段都得出了与 PEL 和 PI 检验相反的结论，在大部分检验阶数下 BG 检验都在 0.01 的显著性水平下拒绝了原假设，少数是在 0.05 的水平下拒绝原假设。我们认为造成 BG 检验得出完全相反结论的原因应该是数据中的异方差性。观察图 3.8，在 BG 检验拒绝原假设的 1927 至 2002 年和 1927 至 1994 年（对应图中的 (a) 和 (b)），数据残差序列可以观察到明显的波动聚集现象，即大的波动倾向于跟着大的波动，小的波动倾向于跟着小的波动，而 (c) 中的残差序列相比之下则更加符合同方差的情况。BG 检验的此种实证结果也与我们模拟部分的结果是相符的。




图 3.8: ARX 模型拟合的残差序列

表 3.7: 预测回归模型的 PEL 检验结果

| 年份区间      | 序列长度 | 外生变量 | 序列相关检验阶数 |         |          |          |         |         |          |          |
|-----------|------|------|----------|---------|----------|----------|---------|---------|----------|----------|
|           |      |      | 2        | 4       | 6        | 8        | 10      | 12      | 14       | 16       |
| 1927-2002 | 912  | LDP  | 0.2727   | 0.1017  | 0.0552*  | 0.0447** | 0.0721* | 0.0981* | 0.0411** | 0.0733*  |
|           |      | LEP  | 0.2692   | 0.0962* | 0.0441** | 0.0345** | 0.0584* | 0.0857* | 0.0311** | 0.0573*  |
| 1927-1994 | 804  | LDP  | 0.2145   | 0.0538* | 0.0355** | 0.0326** | 0.0641* | 0.0886* | 0.0299** | 0.0460*  |
|           |      | LEP  | 0.2317   | 0.0528* | 0.0270** | 0.0248** | 0.0523* | 0.0823* | 0.0221** | 0.0335** |
| 1952-2002 | 612  | LDP  | 0.7848   | 0.8508  | 0.1528   | 0.2762   | 0.4311  | 0.4346  | 0.3533   | 0.4101   |
|           |      | LEP  | 0.7850   | 0.8475  | 0.1466   | 0.2639   | 0.4222  | 0.4401  | 0.3397   | 0.3929   |
|           |      | TBL  | 0.7518   | 0.8740  | 0.1786   | 0.2986   | 0.4620  | 0.4849  | 0.4171   | 0.4522   |
|           |      | LTY  | 0.7788   | 0.8742  | 0.1774   | 0.2948   | 0.4628  | 0.4989  | 0.4006   | 0.4401   |

显著性水平: \*  $P < 0.1$ , \*\*  $P < 0.05$

表 3.8: 金融数据的 ARX 模型序列相关检验结果

| 年份区间      | 序列长度 | 外生变量     | 方法  | 序列相关检验阶数  |           |           |           |           |           |           |           |  |  |  |  |  |
|-----------|------|----------|-----|-----------|-----------|-----------|-----------|-----------|-----------|-----------|-----------|--|--|--|--|--|
|           |      |          |     | 2         | 4         | 6         | 8         | 10        | 12        | 14        | 16        |  |  |  |  |  |
| 1927-2002 | 912  | LDP, LEP | PEL | 0.5270    | 0.2376    | 0.0976*   | 0.1018    | 0.1383    | 0.1858    | 0.0801*   | 0.0980*   |  |  |  |  |  |
|           |      |          | PI  | 0.9720    | 0.2891    | 0.1148    | 0.1034    | 0.1287    | 0.1722    | 0.0892*   | 0.1086    |  |  |  |  |  |
|           |      |          | BG  | 0.0320**  | 0.0137**  | 0.0017*** | 0.0021*** | 0.0011*** | 0.0027*** | 0.0004*** | 0.0003*** |  |  |  |  |  |
| 1927-1994 | 804  | LDP, LEP | PEL | 0.4398    | 0.1600    | 0.0720*   | 0.0805*   | 0.1359    | 0.1984    | 0.0716*   | 0.0755*   |  |  |  |  |  |
|           |      |          | PI  | 0.9958    | 0.2077    | 0.0884*   | 0.0848*   | 0.1310    | 0.1957    | 0.0872*   | 0.0885*   |  |  |  |  |  |
|           |      |          | BG  | 0.0063*** | 0.0054*** | 0.0006*** | 0.0008*** | 0.0006*** | 0.0016*** | 0.0002*** | 0.0001*** |  |  |  |  |  |
| 1952-2002 | 612  | LDP, LEP | PEL | 0.2836    | 0.4779    | 0.0838*   | 0.1453    | 0.2582    | 0.2342    | 0.2476    | 0.2862    |  |  |  |  |  |
|           |      | TBL, LTY | PI  | 0.6568    | 0.8131    | 0.1910    | 0.3092    | 0.4592    | 0.4027    | 0.3940    | 0.4427    |  |  |  |  |  |
|           |      |          | BG  | 0.2187    | 0.4371    | 0.1084    | 0.2206    | 0.3437    | 0.3155    | 0.2825    | 0.3883    |  |  |  |  |  |

显著性水平: \*  $P < 0.1$ , \*\*  $P < 0.05$ , \*\*\*  $P < 0.01$

### 3.4.2 臭氧浓度数据分析

如绪论中所提到的，ARX 模型在环境领域也有着广泛的应用，其一个典型的例子就是污染评估问题。在本小节中我们使用 ARX 模型对 2016 年的一组臭氧数据进行实证分析。该组数据来自美国德克萨斯州的一个环境监测站，可以在美国环境保护局 (United States Environmental Protection Agency, EPA) 的官方网站上下载得到，数据的趋势图可参见图 3.9。

根据 Davis 等 (1998)<sup>[18]</sup> 所述，气象条件会强烈影响臭氧产生的反应速率和完整性，以及随后的传输和消耗，因此，如 Bauer 等 (2001)<sup>[3]</sup> 中的设置，我们添加空气温度、风速、地外辐射和相对湿度四个外生变量。相关气象条件数据收集自位于美国德克萨斯州布什兰的美国农业部农业研究服务保护与生产研究实验室 (U.S Department of Agriculture, Agricultural Research Service, Conservation and Production Research Laboratory: Bushland, Texas)。




图 3.9: 臭氧浓度趋势图

本小节使用的臭氧数据包含 2016 年 6 月 27 日至 2016 年 7 月 10 日间的一些缺失值。为了避免直接剔除该段数据或使用插补方法可能带来的偏误等不良影响，本文选择将样本数据分段讨论，分别为 2016 年 1 月 1 日至 2016 年 6 月 26 日和 2016 年 7 月 11 日至 2016 年 12 月 31 日。值得注意的是，Bauer 等 (2001)<sup>[3]</sup> 文中



基于每小时数据的分析结果表明,模型设定中自回归结构的滞后阶数应该在 48 期以上,而在本文中我们所使用的是日度数据,因此我们选择臭氧浓度数据自身的一阶与二阶滞后作为两个预测变量。

接下来,我们分别使用 PEL, PI, BG 三种序列相关检验方法对上述的 ARX 模型拟合结果进行检验,检验结果为表 3.9 所示。从该表可以看到,对于 2016 年 1 月 1 日至 2016 年 6 月 26 日的时间段,至少在低阶滞后 (10 阶以内) 的范围内在 0.05 的显著性水平上不能做出拒绝原假设的推断,这表明该情况下拟合残差不存在序列相关性,模型的拟合较为合适。然而,在 2016 年 7 月 11 日至 2016 年 12 月 31 日的时间段,PEL 检验的结果是在设定的每种检验阶数下都应该在 0.01 的显著性水平下拒绝原假设,检验十分显著。该结论与 Bauer 等 (2001)<sup>[3]</sup> 中 ARX 模型可能无法充分拟合类似的数据的结论是相符的,并且我们可能有必要考虑像 ARXd 或 ARXr 之类更加复杂的模型。

然而对于 PI 检验,其不论是在第一个还是第二个样本区间,以及所有的检验阶数上都以很大的 P 值做出了接受原假设的推断。如果按照该结果认为此处进行的 ARX 建模是恰当的,这将与以前的研究结果相矛盾。为此我们对拟合得到的两个误差项  $U_t$  和  $V_t$  进行了 Pearson 相关检验以探究可能导致这种矛盾的原因,Pearson 检验的结果均在 0.05 的显著性水平下拒绝了两者之间不相关的原假设。因此,此处 PI 检验出现的错误很有可能也是由  $U_t$  和  $V_t$  之间的相关性所导致的。

最后观察 BG 检验的结果,可以看到其在 2016 年 1 月 1 日至 2016 年 6 月 26 日的样本段对于所有检验阶数都得到了接受原假设的结果,而对于 2016 年 7 月 11 日至 2016 年 12 月 31 日的时间段,除了二阶与四阶分别是 0.05 与 0.1 的水平下拒绝外,也全部做出了接受原假设的推断。考虑到模拟部分表 3.4 - 3.6 中所示,BG 检验在异方差的条件下拥有偏大的 Size,这表明异方差的出现将使 BG 检验统计量的分布右偏。而此处的实证结果中 BG 检验具有较大的 P 值,可以说明该类型的环境气象数据是不存在异方差性的。

表 3.9: 环境数据的 ARX 模型序列相关检验结果

| 日期区间       | 序列长度 | 方法  | 序列相关检验阶数  |           |           |           |           |           |           |           |
|------------|------|-----|-----------|-----------|-----------|-----------|-----------|-----------|-----------|-----------|
|            |      |     | 2         | 4         | 6         | 8         | 10        | 12        | 14        | 16        |
| 1.1-6.26   | 178  | PEL | 0.2817    | 0.0562*   | 0.0773*   | 0.0738*   | 0.0536*   | 0.0499**  | 0.0690*   | 0.0231**  |
|            |      | PI  | 0.6555    | 0.1883    | 0.2412    | 0.3223    | 0.4602    | 0.3379    | 0.2664    | 0.1787    |
|            |      | BG  | 0.2939    | 0.1029    | 0.1773    | 0.2124    | 0.2545    | 0.3236    | 0.3637    | 0.3682    |
| 7.11-12.31 | 173  | PEL | 0.0038*** | 0.0021*** | 0.0033*** | 0.0074*** | 0.0085*** | 0.0075*** | 0.0052*** | 0.0011*** |
|            |      | PI  | 0.7063    | 0.9547    | 0.8998    | 0.8022    | 0.6021    | 0.5958    | 0.4126    | 0.2402    |
|            |      | BG  | 0.0352**  | 0.0686*   | 0.1856    | 0.2614    | 0.2499    | 0.3011    | 0.2450    | 0.2852    |

显著性水平: \*  $P < 0.1$ , \*\*  $P < 0.05$ , \*\*\*  $P < 0.01$

## 4 总结与展望

### 4.1 总结

ARX 模型是时间序列分析中的常用模型,其结合自回归项与外生变量的结构使得它拥有了远超自回归模型或简单线性回归的应用场景。在诸如金融统计建模、环境监测、机械工程等众多学科方向,均可见到 ARX 模型的广泛应用。

在回归分析,特别是时间序列相关的模型拟合中,序列相关检验是一个非常重要的步骤。表现出序列相关性的误差项往往意味着拟合结果不佳、存在模型误设等严重问题。虽然目前已有不少文献针对该问题做出了杰出的工作,但是近年来,实证经济学家发现在实际金融数据中,广泛存在着波动聚集、异方差、重尾,以及误差项序列之间强相关等问题,而这些现象对于现存的序列相关检验方法的稳健性造成了极大的破坏。面对这些新的挑战,学界与业界都迫切需要一个满足在所有上述条件下都适用的检验方法。

有鉴于此,本文基于剖面优化经验似然(Profile Empirical Likelihood, PEL)为 ARX 模型提出了一个新的序列相关检验方法,并将其数值模拟的结果与现存的 PI(Plug-In)经验似然检验和 BG(Breusch-Godfrey)检验进行了对比。数值模拟的结果表明,相较 PI 方法在误差项序列之间强相关的情况下严重 Undersized,以及 BG 方法在条件异方差的情况下严重 Oversized 的表现,本文所提的 PEL 方法因其在上述所有考虑到的情况下都保持了准确的 Size,故而拥有最佳的稳健性质。PEL 序列相关检验方法的提出扩展了现有检验方法的应用所受到的局限,因而具有较大的实际意义。

除此之外,本文还将 PEL 序列相关检验应用于实证研究中。我们分别对一组美国股市股票收益率、市盈率、股息率等的金融数据与一组臭氧浓度、风速、湿度等的环境数据进行了 ARX 模型拟合与序列相关检验。第一个例子表明,相比传统的预测回归模型,带有自回归项的 ARX 模型在拟合预测股票收益等金融变量方面更为适用且恰当。第二个例子表明,本文中用四组外生气象变量数据对臭氧浓度这一指标进行拟合的结果可能并不充分,污染评估所涉及到的变量可能更多,或者存在模型选择方面的问题,实证研究者需要考虑更加复杂的模型。

## 4.2 展望

虽然 PEL 序列相关检验行之有效，充分扩展了现存序列相关检验方法的应用场景，但它也不可避免地存在缺点。例如，PEL 方法相比 PI 方法，其数值计算增加了参数的剖面优化这一过程，而这是一个需要代入大量循环迭代的步骤，因此其需要的计算量有了数量级上的增加。对于涉及到高维参数，或者需要检验多阶滞后的序列相关的情况，PEL 方法相比现存方法需要大量额外的计算成本，使用者或许也得忍受计算缓慢的问题。

再者，相比现存方法基本是基于最小二乘残差的“插入”方法，PEL 方法的算法本身也具有较高的复杂性。基于 OLS 估计的方法所代入检验的数据是拟合之后的残差序列，故其应用较为简便，在编程上也可以利用现有的模型拟合程序进行“两步骤”操作，即先进行模型拟合和参数求解，后利用拟合残差进行序列相关检验。这意味着模型拟合和序列相关检验是可以完全分开的两个步骤。然而 PEL 序列相关检验其实是一个融合了回归系数估计与序列相关检验的综合程序。在 PEL 方法中，OLS 方法下的正交方程与检验序列相关性的 Score 函数同时被写进了经验似然的估计方程中，而这意味着 PEL 方法是与预设的模型息息相关的，即对于不同的预设模型，需要有专属于该模型的 PEL 方法与对应程序。这种复杂性不仅增加了程序编写者的工作量，同时也为 PEL 序列相关检验的广泛应用带来了困难，使得该方法很难似 DW 检验、Portmanteau 检验与 PI 检验一般迅速大量应用于业界。

## 参考文献

- [1] Amihud, Y., Hurvich, C.M. Predictive regressions: A reduced-bias estimation method[J]. Journal of Financial and Quantitative Analysis, 2004, 39, 813-841.
- [2] Astuti, D., Ruchjana, B.N. Generalized space time autoregressive with exogenous variable model and its application[J]. Journal of Physics: Conference Series, 2017, 893, 012038.
- [3] Bauer, G., Deistler, M., Scherrer, W. Time series models for short term forecasting of ozone in the eastern part of Austria[J]. Environmetrics: The Official Journal of the International Environmetrics Society, 2001, 12, 117-130.
- [4] Bierens, H.J. Least squares estimation of linear and nonlinear ARMAX models under data heterogeneity[J]. Annales d'Economie et de Statistique, 1990, 143-169.
- [5] Box, G.E., Jenkins, G.M., Reinsel, G.C., Ljung, G.M. Time Series Analysis: Forecasting and Control[M]. John Wiley & Sons: Hoboken, NJ, USA, 2015.
- [6] Breusch, T.S. Testing for autocorrelation in dynamic linear models[J]. Australian Economic Papers, 1978, 17, 334-355.
- [7] Bollerslev, T. Generalized autoregressive conditional heteroskedasticity[J]. Journal of Econometrics, 1986, 31, 307-327.
- [8] Box, G.E., Pierce, D.A. Distribution of residual autocorrelations in autoregressive-integrated moving average time series models[J]. Journal of the American Statistical Association, 1970, 65, 1509-1526.
- [9] Cai, Z., Chen, H., Liao, X. A new robust inference for predictive quantile regression[J]. Journal of Econometrics, 2022.

- [10] Cai, Z., Masry, E. Nonparametric estimation of additive nonlinear ARX time series: Local linear fitting and projections[J]. *Econometric Theory*, 2000, 16, 465–501.
- [11] Campbell, J.Y., Yogo, M. Efficient tests of stock return predictability[J]. *Journal of Financial Economics*, 2006, 81, 27-60.
- [12] Chang, J., Chen, S.X., Tang, C.Y., Wu, T.T. High-dimensional empirical likelihood inference[J]. *Biometrika*, 2021, 108, 127-147.
- [13] Chang, J., Tang, C.Y., Wu, T.T. A new scope of penalized empirical likelihood with high-dimensional estimating equations[J]. *The Annals of Statistics*, 2018, 46, 3185-3216.
- [14] Chen, C.W., Chiu, L.M. Ordinal time series forecasting of the air quality index[J]. *Entropy*, 2021, 23, 1167.
- [15] Chen, S.X., Van Keilegom, I. A review on empirical likelihood methods for regression[J]. *Test*, 2009, 18, 415-447.
- [16] Chen, W.W., Deo, R.S. Bias reduction and likelihood-based almost exactly sized hypothesis testing in predictive regressions using the restricted likelihood[J]. *Econometric Theory*, 2009, 25, 1143-1179.
- [17] Chitturi, R.V. Distribution of residual autocorrelations in multiple autoregressive schemes[J]. *Journal of the American Statistical Association*, 1974, 65, 1509–1526.
- [18] Davis, J.M., Eder, B.K., Bloomfield, P. Modeling ozone in the Chicago urban area[J]. *Case Studies in Environmental Statistics*, 1998, 5-26.
- [19] DiCiccio, T., Hall, P., Romano, J. Empirical likelihood is Bartlett-correctable[J]. *The Annals of Statistics*, 1991, 1053-1061.

- [20] Dickey, D.A., Fuller, W.A. Distribution of the estimators for autoregressive time series with a unit root[J]. Journal of the American Statistical Association, 1979, 74, 427–431.
- [21] Durbin, J., Watson, G.S. Testing for serial correlation in least squares regression[J]. Biometrika, 1950, 37, 409–428.
- [22] Engle, R.F. Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation[J]. Econometrica: Journal of the Econometric Society, 1982, 987–1007.
- [23] Fama, E.F., French, K.R. Dividend yields and expected stock returns[J]. Journal of Financial Economics, 1988, 22, 3–25.
- [24] Fama, E.F., Schwert, G.W. Asset returns and inflation[J]. Journal of Financial Economics, 1977, 5, 115–146.
- [25] Fisher, T.J., Gallagher, C.M. New weighted portmanteau statistics for time series goodness of fit testing[J]. Journal of the American Statistical Association, 2012, 107, 777–787.
- [26] Francq, C., Roy, R., Zakoïan, J.M. Diagnostic checking in ARMA models with uncorrelated errors[J]. Journal of the American Statistical Association, 2005, 100, 532–544.
- [27] Godfrey, L.G. Testing against general autoregressive and moving average error models when the regressors include lagged dependent variables[J]. Econometrica: Journal of the Econometric Society, 1978, 46, 1293–1301.
- [28] Hall, P., Heyde, C.C. Martingale Limit Theory and Its Application[M]. Academic Press: Cambridge, MA, USA, 2014.
- [29] Hall, P., La Scala, B. Methodology and algorithms of empirical likelihood[J]. International Statistical Review/Revue Internationale de Statistique, 1990, 109–127.

- [30] Hamilton, J.D. Time Series Analysis[M]. Princeton University Press, 2020.
- [31] Hosking, J.R.M. The multivariate portmanteau statistic[J]. Journal of the American Statistical Association, 1980, 75, 343–386.
- [32] Hosking, J.R.M. Equivalent forms of the multivariate portmanteau statistic[J]. Journal of the Royal Statistical Society: Series B, 1981, 43, 261–262.
- [33] Jing, B.Y., Yuan, J., Zhou, W. Jackknife empirical likelihood[J]. Journal of the American Statistical Association, 2009, 104, 1224-1232.
- [34] Keim, D.B., Stambaugh, R.F. Predicting returns in the stock and bond markets[J]. Journal of Financial Economics, 1986, 17, 357-390.
- [35] Kitamura, Y. Empirical likelihood methods in econometrics: Theory and practice[J]. Cowles Foundation Discussion Paper, 2006.
- [36] Lazar, N.A. Bayesian empirical likelihood[J]. Biometrika, 2003, 90, 319-326.
- [37] Lazar, N.A. A review of empirical likelihood[J]. Annual Review of Statistics and Its Application, 2021, 8, 329-344.
- [38] Li, Q., Tan, X., Wang, L. Testing for error correlation in partially functional linear regression models[J]. Communications in Statistics-Theory and Methods, 2021, 50, 747-761.
- [39] Liu, X., Yang, B., Cai, Z., Peng, L. A unified test for predictability of asset returns regardless of properties of predicting variables[J]. Journal of Econometrics, 2019, 208, 141-159.
- [40] Ljung, G.M., Box, G.E. On a measure of lack of fit in time series models[J]. Biometrika, 1978, 65, 297–303.
- [41] Mandelbrot, B. New methods in statistical economics[J]. Journal of Political Economy, 1963, 71, 421–440.



- [42] Li, M., Zhang, Y. Bootstrapping multivariate portmanteau tests for vector autoregressive models with weak assumptions on errors[J]. Computational Statistics & Data Analysis, 2022, 165, 107321.
- [43] Owen, A.B. Empirical likelihood ratio confidence intervals for a single functional[J]. Biometrika, 1988, 75, 237-249.
- [44] Owen, A.B. Empirical likelihood confidence regions[J]. The Annals of Statistics, 1990, 18, 90-120.
- [45] Owen, A.B. Empirical likelihood for linear models[J]. The Annals of Statistics, 1991, 19, 1725-1747.
- [46] Owen, A.B. Empirical likelihood[M]. Chapman and Hall/CRC, 2001.
- [47] Qin, J., Lawless, J. Empirical likelihood and general estimating equations[J]. The Annals of Statistics, 1994, 22, 300-325.
- [48] Romano, J.P., Thombs, L.A. Inference for autocorrelations under weak assumptions[J]. Journal of the American Statistical Association, 1996, 91, 590-600.
- [49] Said, S.E., Dickey, D.A. Testing for unit roots in autoregressive-moving average models of unknown order[J]. Biometrika, 1984, 71, 599-607.
- [50] Stambaugh, R.F. Predictive regressions[J]. Journal of Financial Economics, 1999, 54, 375-421.
- [51] Stein, E.M., Shakarchi, R. Real Analysis[M]. Princeton Lectures in Analysis, 2005.
- [52] Thomas, D.R., Grunkemeier, G.L. Confidence interval estimation of survival probabilities for censored data[J]. Journal of the American Statistical Association, 1975, 70, 865-871.
- [53] Van der Vaart, A.W. Asymptotic Statistics[M]. Cambridge University Press, 2000.

- [54] Van der Vaart, A.W. Time Series[M]. VU University Amsterdam, Lecture Notes, 2010.
- [55] Wang, C., Chan, K.S. Quasi-likelihood estimation of a censored autoregressive model with exogenous variables[J]. Journal of the American Statistical Association, 2018, 113, 1135–1145.
- [56] Warsono, W., Russel, E., Wamiliana, W., Widiarti, W., Usman, M. Vector autoregressive with exogenous variable model and its application in modeling and forecasting energy data: Case study of PTBA and HRUM energy[J]. International Journal of Energy Economics and Policy, 2019, 9, 390–398.
- [57] Wilks, S.S. The large-sample distribution of the likelihood ratio for testing composite hypotheses[J]. The Annals of Mathematical Statistics, 1938, 9, 60-62.
- [58] Yule, G.U. On a method of investigating periodicities in disturbed series with special reference to Wolfer' s sunspot numbers[J]. Philosophical Transactions of the Royal Society of London. Series A, 1927, 226, 267–298.
- [59] Zhu, F., Cai, Z., Peng, L. Predictive regressions for macroeconomic data[J]. The Annals of Applied Statistics, 2014, 8, 577–594.
- [60] Zhu, K. Bootstrapping the portmanteau tests in weak auto-regressive moving average models[J]. Journal of the Royal Statistical Society: Series B, 2016, 463-485.
- [61] 范雅文, 刘小惠. 预测回归模型序列相关性的 Jackknife 经验似然比检验 [J]. 系统科学与数学, 2019, 39(09): 1471-1485.
- [62] 刘锋, 陈敏, 邹捷中. 部分线性模型序列相关的经验似然比检验 [J]. 应用数学学报, 2006(04): 577-586.
- [63] 王启华. 经验似然统计推断方法发展综述 [J]. 数学进展, 2004(02): 141-151.
- [64] 郑忠国. 随机加权法 [J]. 应用数学学报, 1987(02): 247-253.

